

Сдаем экспериментально-опытное обучение интерпретируемым пожизненно!

(Make experiential life-long learning interpretable!)

Антон Колонин

akolonin@aigents.com

Telegram: akolonin



<https://agirussia.org>

Есть ли у нас проблемы?

Медленно обучаемся?

=> slow learning

Не можем объяснить свои решения?

=> uninterpretable models

Забываем важное?

=> catastrophic forgetting

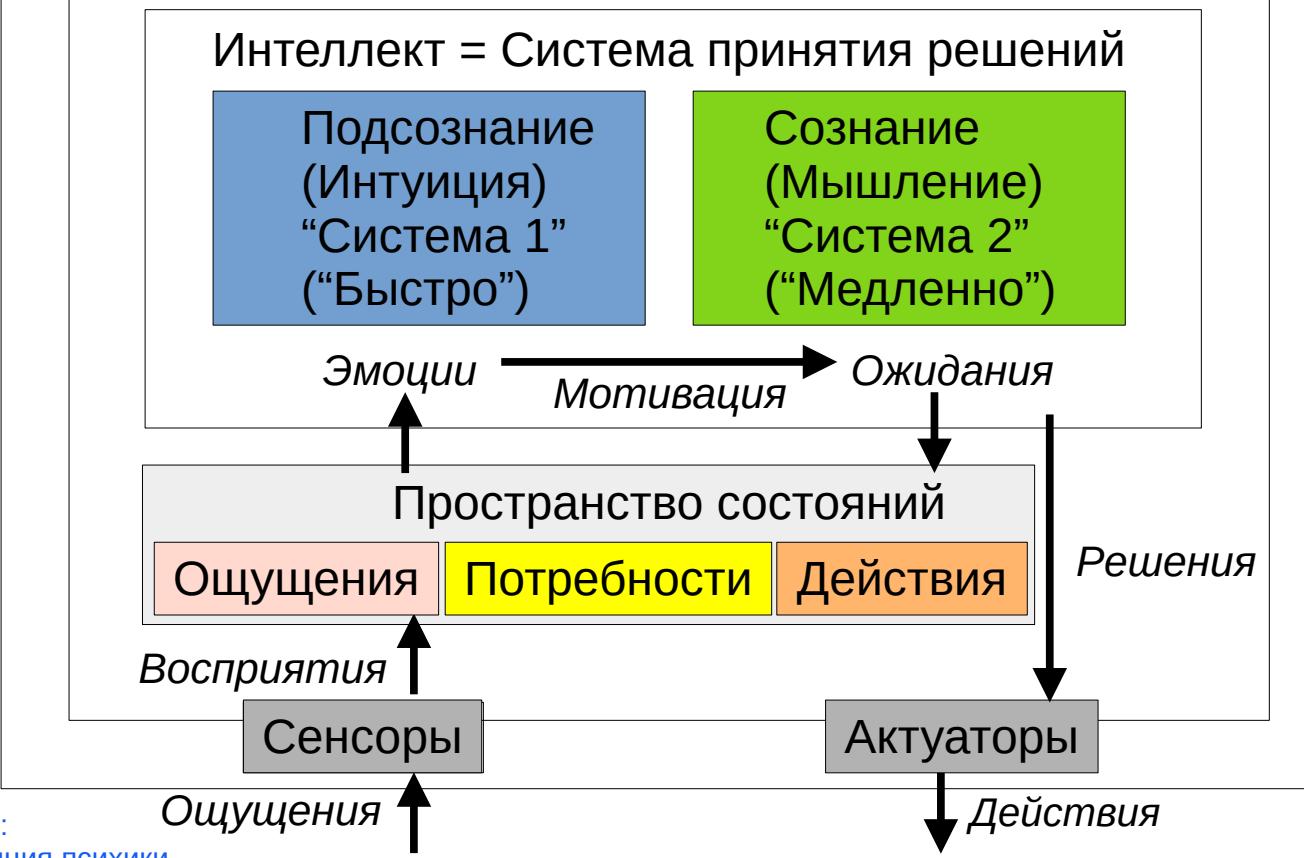
Тратим много энергии?

=> expensive, resource-consuming training

Система = Интеллектуальный Агент

Психика = Операционная система

Интеллект = Система принятия решений

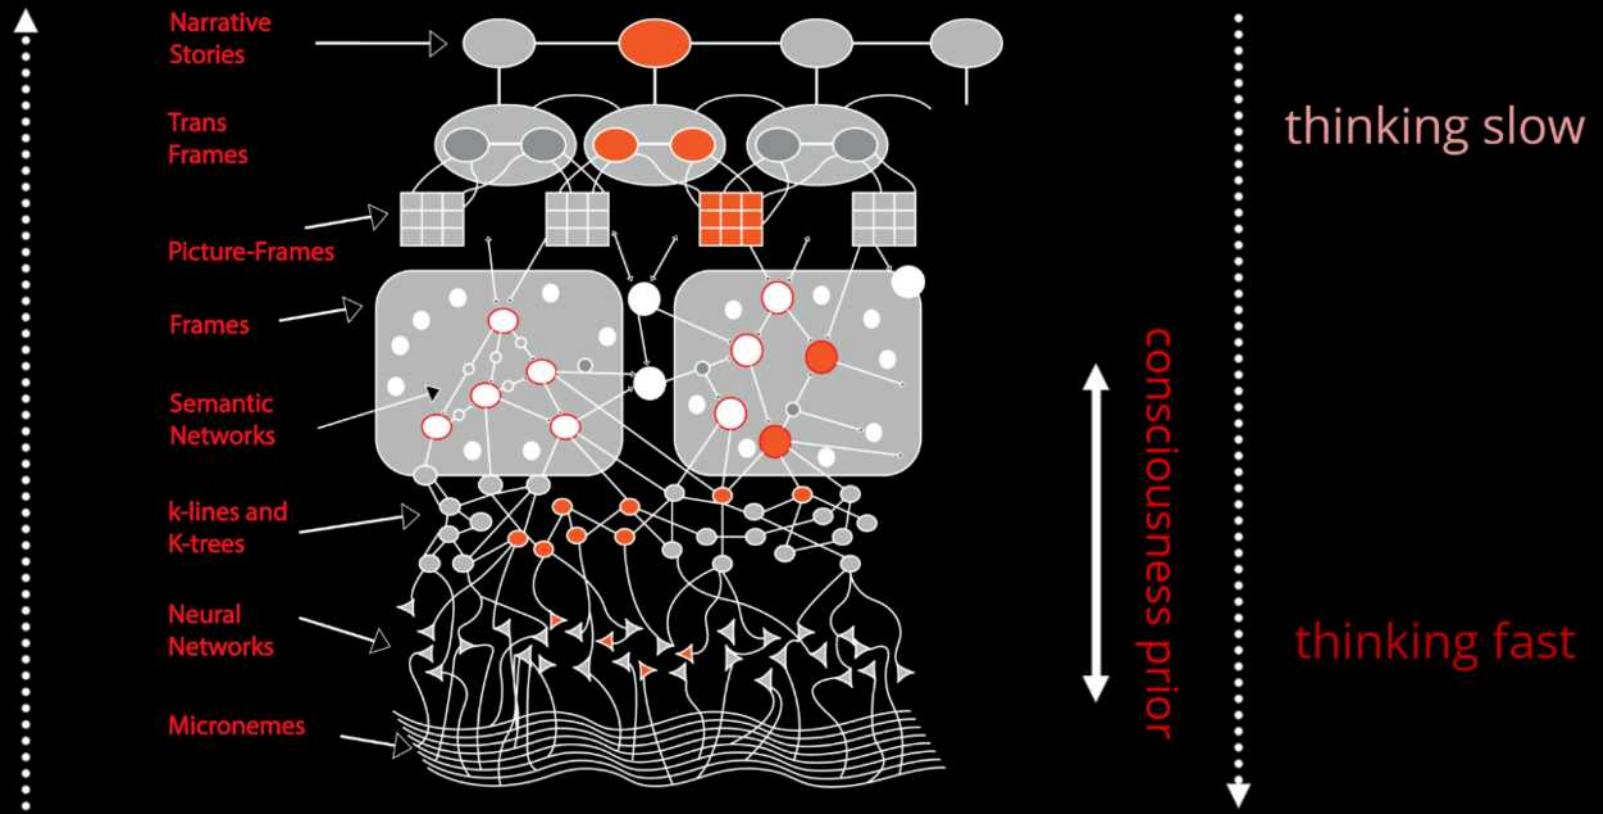


А.Г.Колонин, В.Г.Крюков:
Вычислительная концепция психики,
Статья принята на конференцию
Нейроинформатика-25

“Быстрое и медленное мышление” – Daniel Kahneman

easy
explanation
learning fast

hard
explanation
learning slow



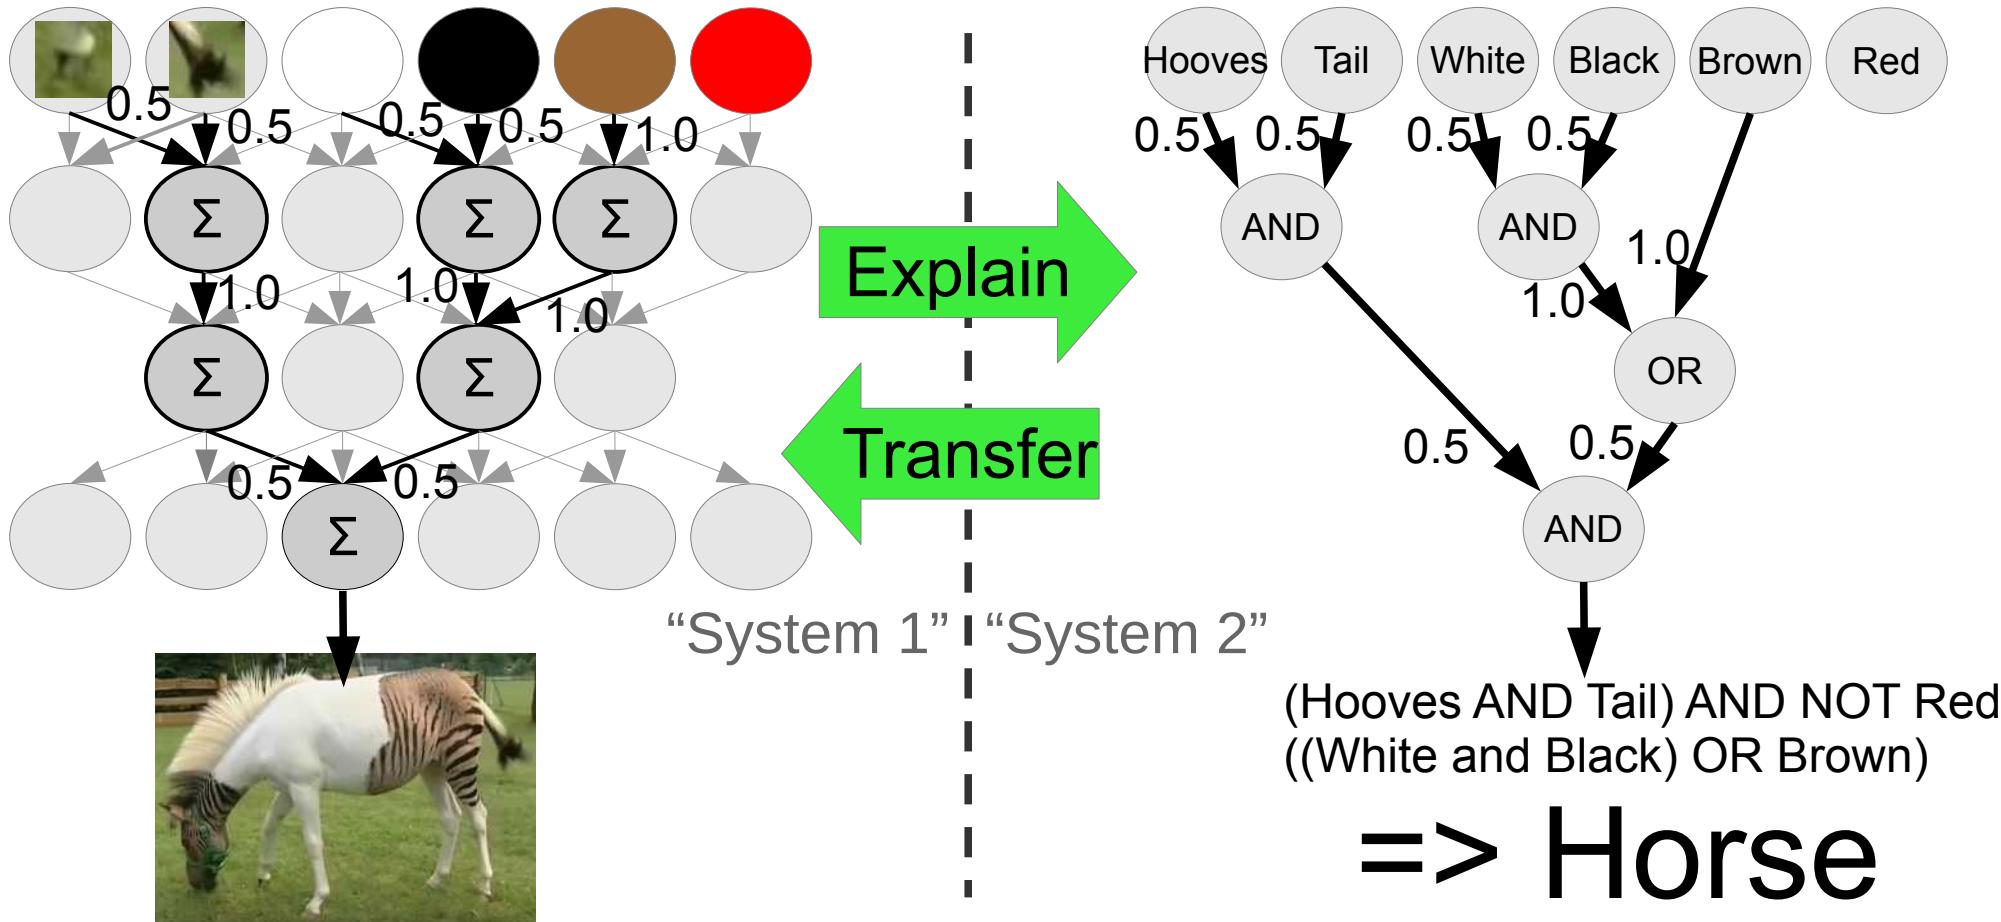
<https://www.linkedin.com/pulse/explainable-ai-vs-explaining-part-1-ahmad-haj-mosa/>

Xing, F., Cambria, E., Welsch, R. (2019). Theoretical Underpinnings on Text Mining. In: Intelligent Asset Management. Socio-Affective Computing, vol 9. Springer, Cham.
https://doi.org/10.1007/978-3-030-30263-4_3

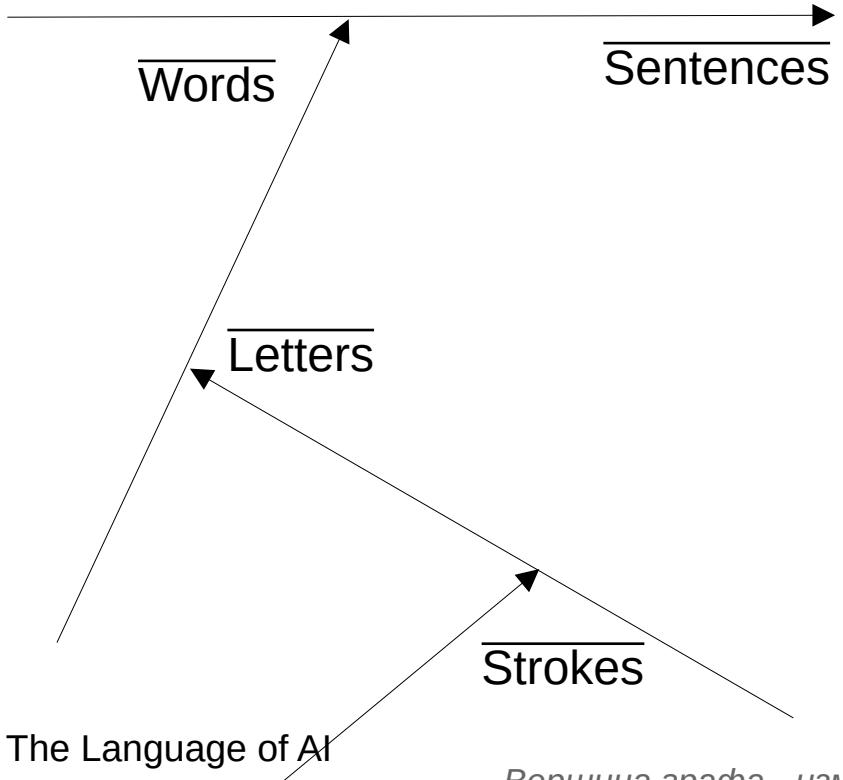
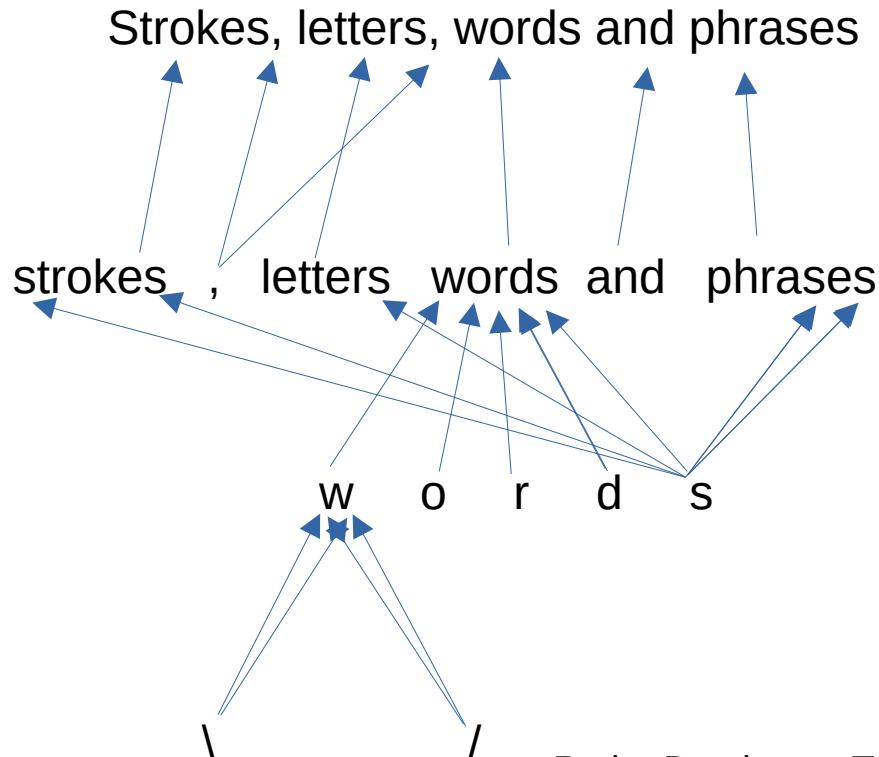
M. Minsky, The Emotion Machine: Commonsense Thinking, Artificial Intelligence, and the Future of the Human Mind (Simon & Schuster Paperbacks, Princeton, 2007)

Copyright © 2026 Anton Kolonin, Agents®

Нейро-символьная интеграция для интерпретируемого ИИ



Функциональная эквивалентность графовых и нейросетевых тензорных моделей



Pedro Domingos, Tensor Logic: The Language of AI
<https://arxiv.org/pdf/2510.12269>

Copyright © 2026 Anton Kolonin, Aigents®

Вершина графа - измерение
Ребро графа - вектор
Гиперграф - тензор

Типизированная тензорная логика для различных систем ИИ (logical, sub-symbolic, probabilistic/non-axiomatic)

Truth-Value Tensor (NARS/PLN/...)

Numerical Tensor (ANN/Bayesian Logic)

Boolean Tensor

(Boolean Logic)

Property 0.0123456
↑ =750/60750



Property
↑
 ~ 0.01



Property
↑
False



Life-long learning?

Subject

Pei Wang: Non-Axiomatic Logic
<https://www.worldscientific.com/>

Pedro Domingos, Tensor Logic: The Language of AI
<https://arxiv.org/pdf/2510.12269>

Психика = Операционная система

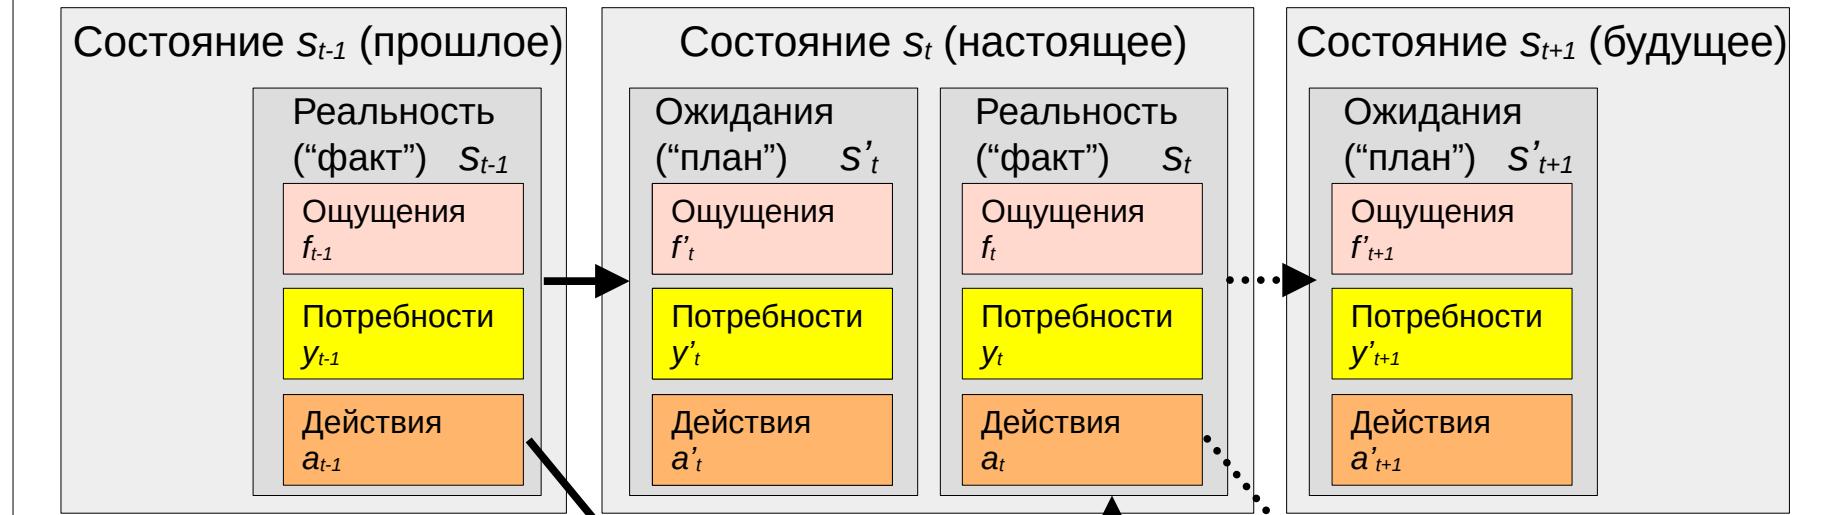
Интеллект = Система принятия решений

Модели s ("инварианты") состояний, полезности U и вероятности P переходов
 $U(\{S_t\}_{t \in \{-T, -1\}}, S'_0) = L(x \cdot (y_t - y_{t+1}), s'_t - s_t, E(a_t))$ $s'_t = \text{argmax}_s(U(\{S_t\}_{t \in \{-T, t-1\}}, s'_t), P(\{S_t\}_{t \in \{-T, t-1\}}, s'_t))$

↑Обучение на опыте

↓Принятие решений

Пространство состояний и эпизодическая память ("прецеденты")



Энергоэффективность
 a

Психика = Операционная система

Оптимальное решение
и ожидание s

Предсказумость
 s

Интеллект = Система принятия решений

Ожидаемая
полезность s

Модели s ("инварианты") состояний, полезности U и вероятности P переходов
 $U(\{S_t\}_{t \in \{-T, -1\}}, S'_0) = L(x \cdot (y_t - y_{t+1}), s'_t - s_t, E(a_t))$ $s'_t = \text{argmax}_s(U(\{S_t\}_{t \in \{-T, t-1\}}, S'_t), P(\{S_t\}_{t \in \{-T, t-1\}}, S'_t))$

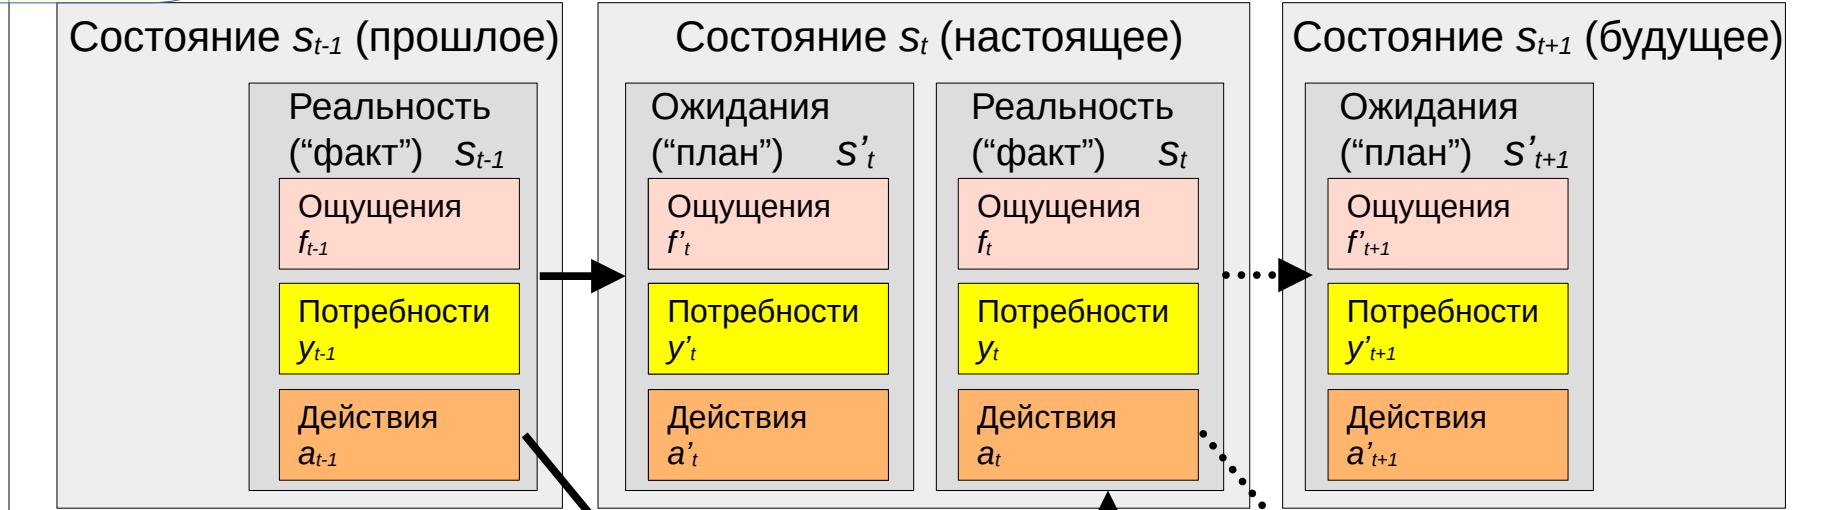
↑Обучение на опыте

↓Принятие решений

Ожидаемая
вероятность s

Удовлетворенность
 y

Пространство состояний и эпизодическая память ("прецеденты")

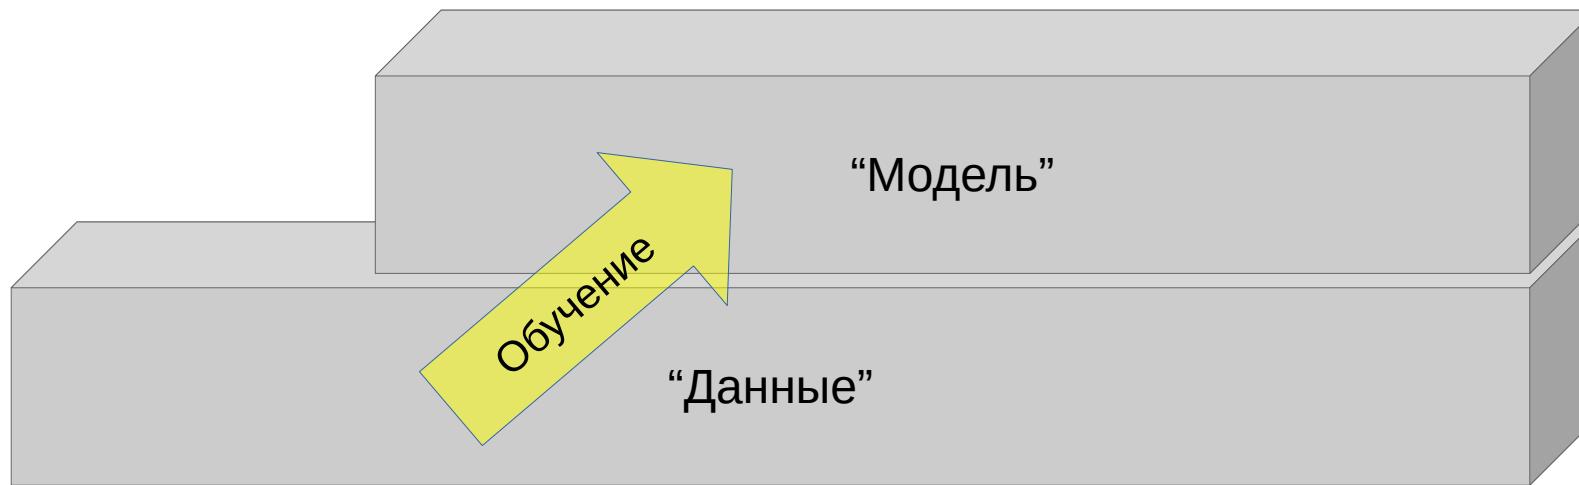


$x \cdot y_t$ – "мотивационный вектор"

V. F. Petrenko and A. P. Suprun, "Goal oriented systems, evolution, and the subjective aspect in systemology," Tr. Inst. Sistem. Analiza RAN 62 (1) (2012)

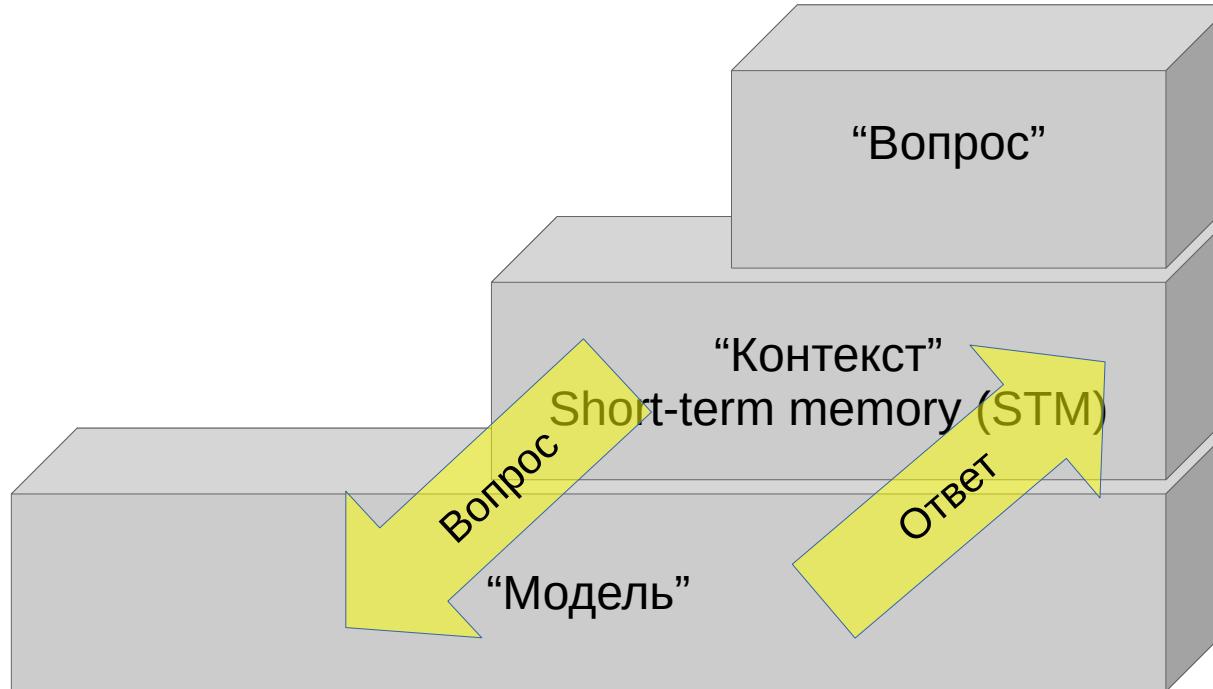
Кластеризация состояний?
Асинхронная их обработка?

Обучение модели (БЯМ) - Training/Learning



Модель замораживается после обучения

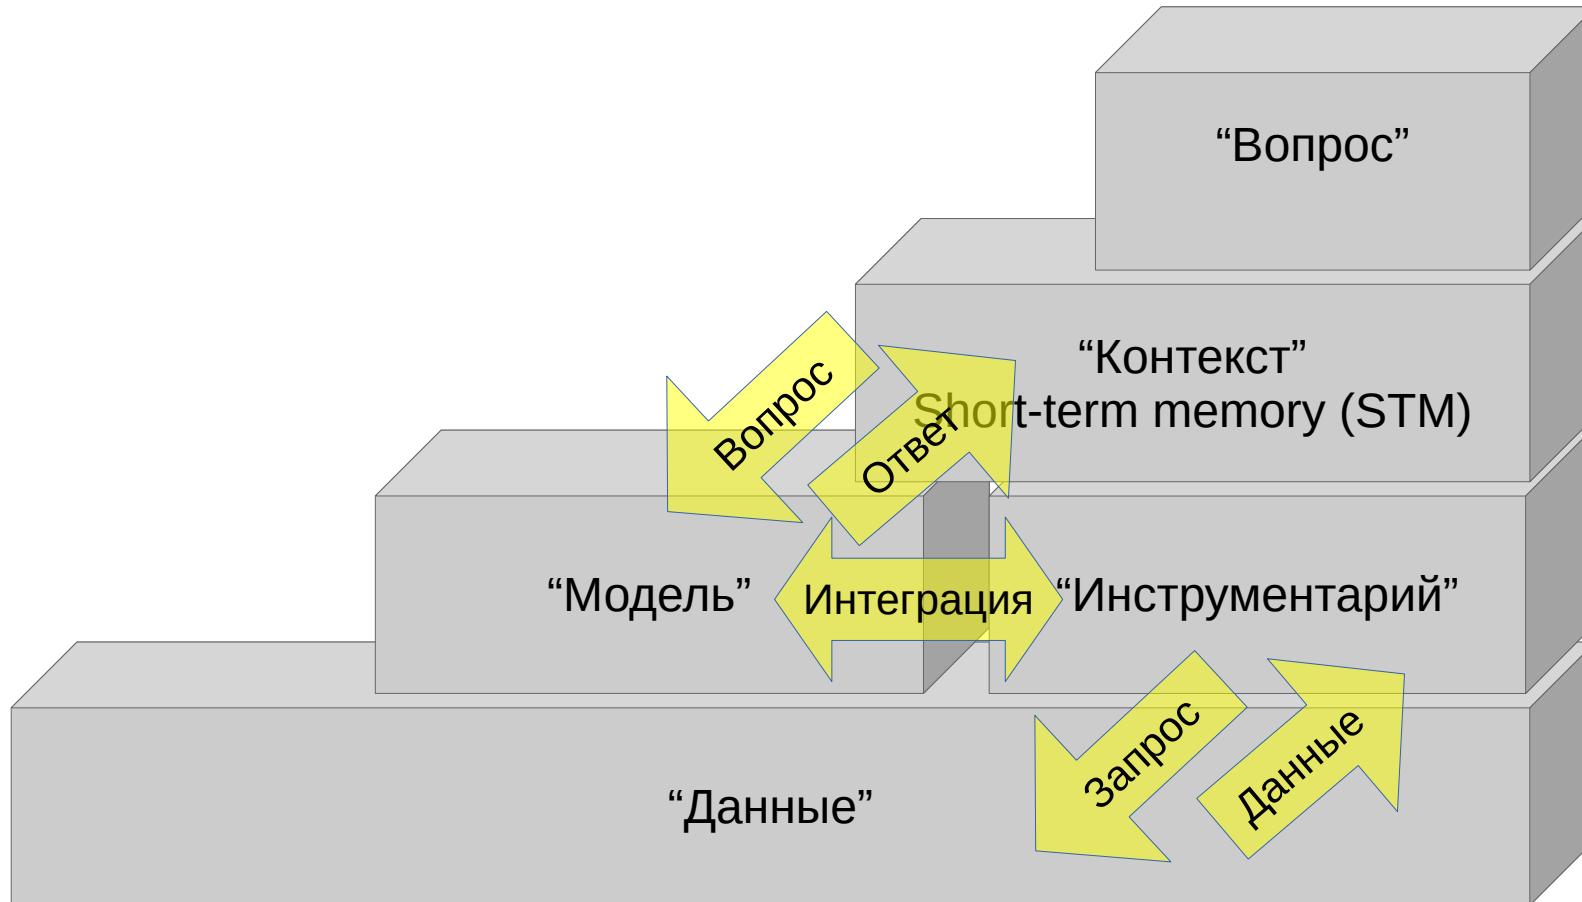
Использование модели (БЯМ) - Inference



Данные не участвуют в выводе

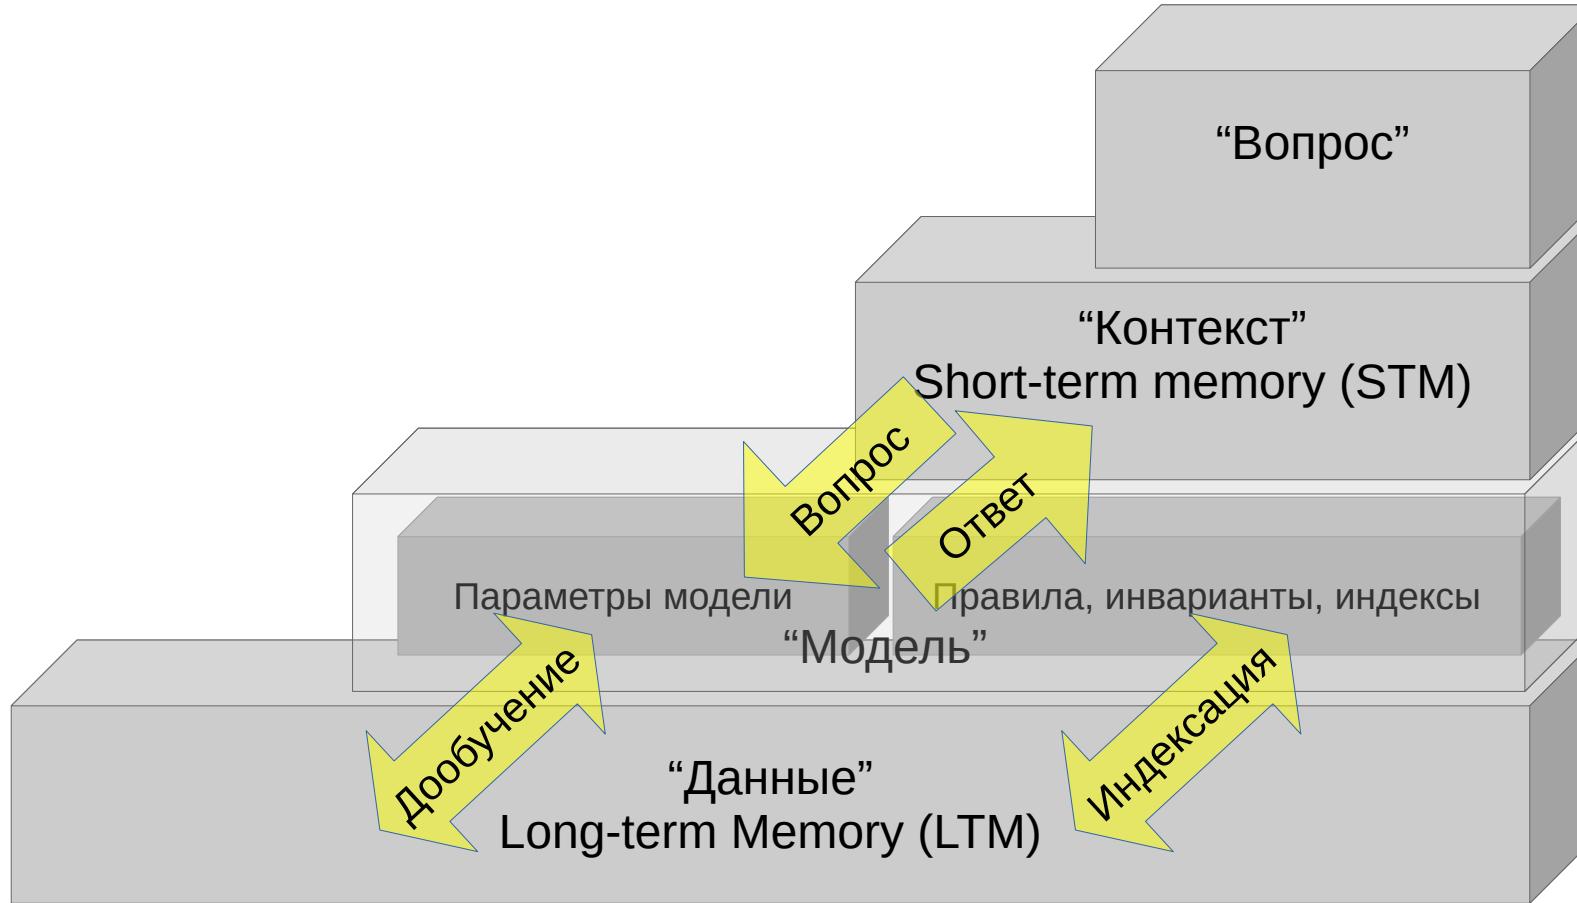
Новые данные и контексты требуют переобучения на старых и новых
На это все может не хватить параметров конкретной модели

Много-агентные модели (БЯМ+RAG/GraphRAG)



Данные могут подкачиваться в контекст и обновляться с его учетом
Модель все равно требует переобучения с учетом новых данных

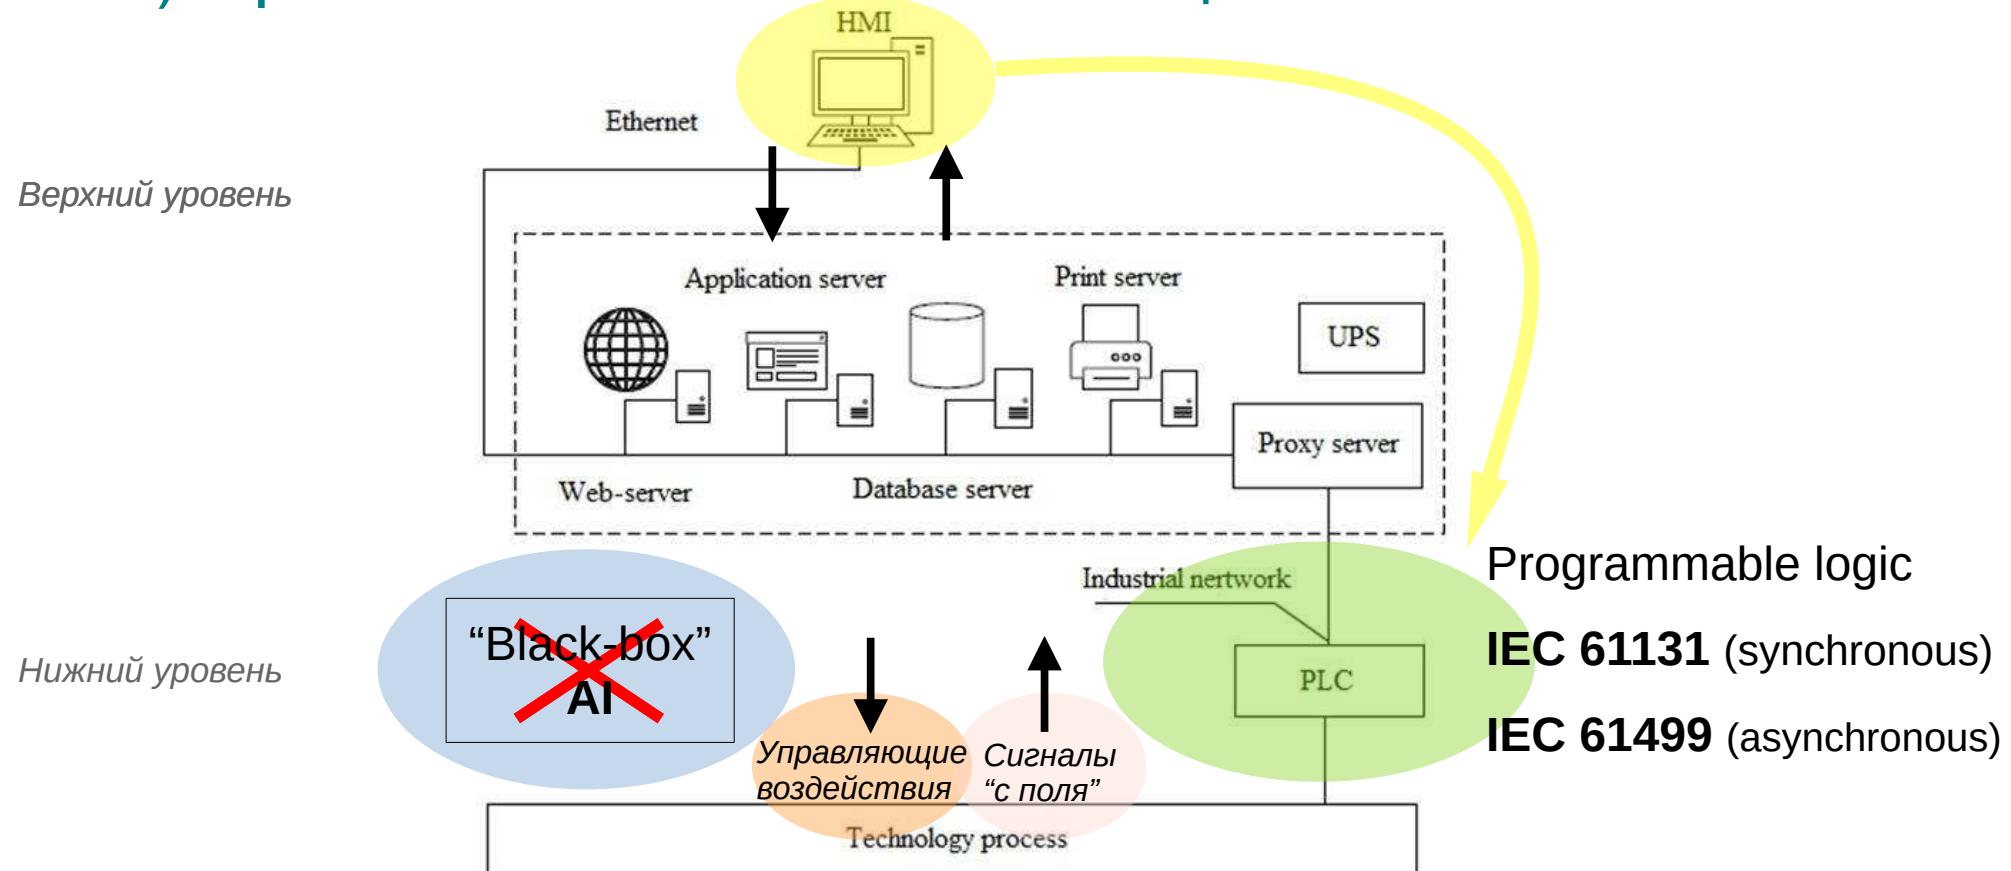
Гибридная архитектура с долгосрочной памятью



Возможно инкрементальное “дообучение” на динамически пополняющихся данных
Динамически обновляющиеся данные могут инкрементально обновлять соответствующие “инварианты”

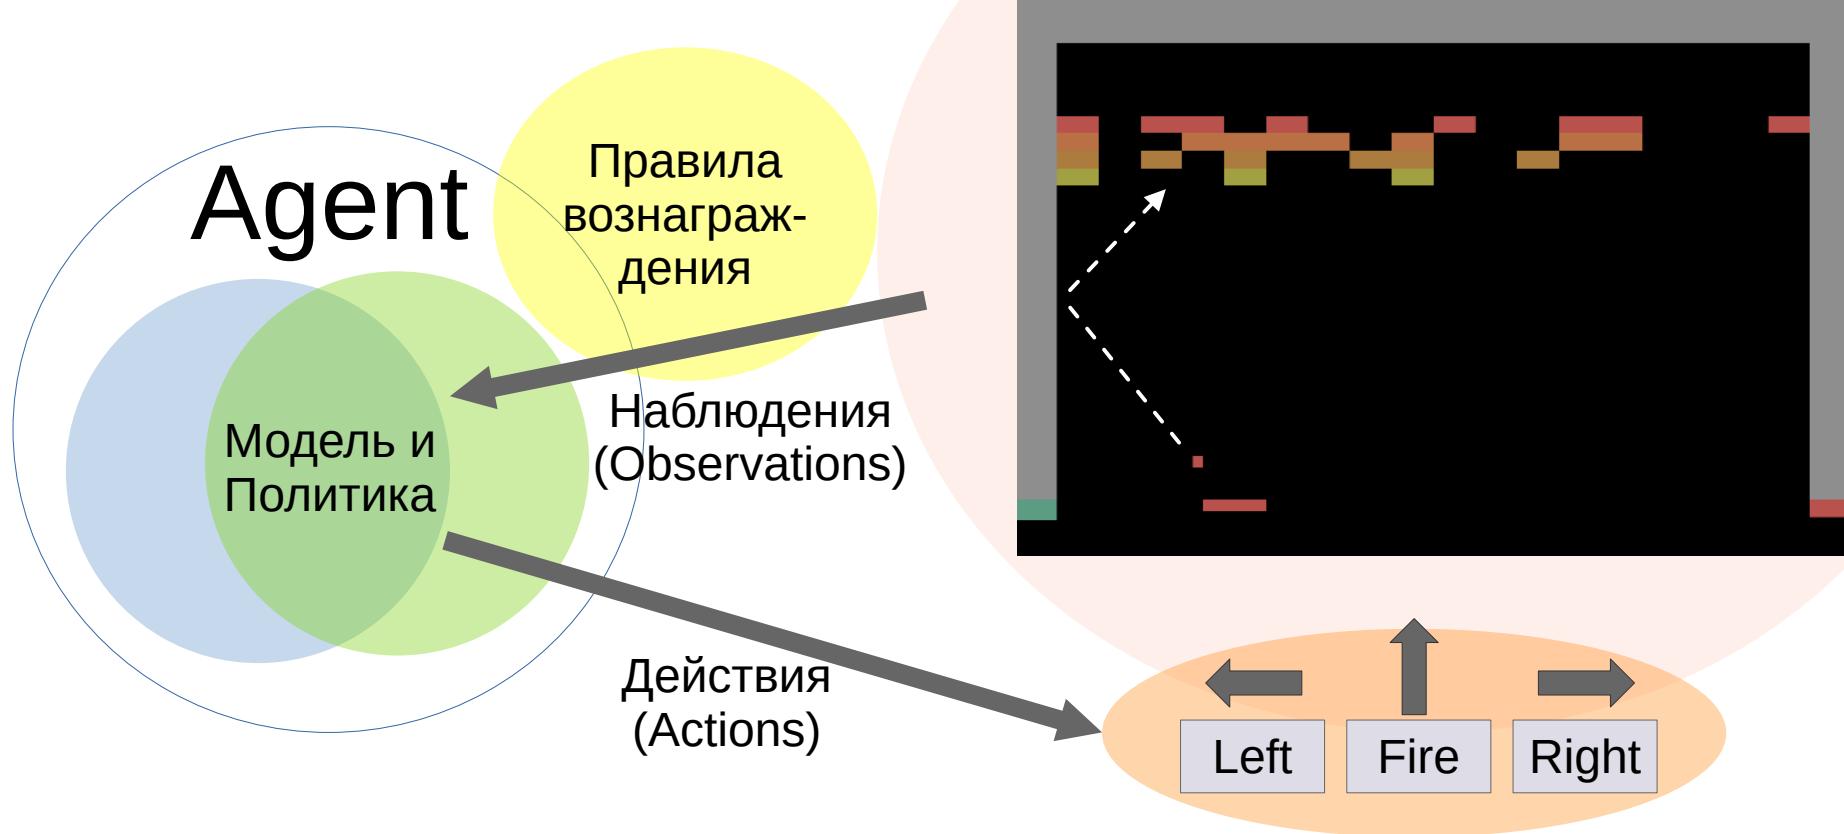
Применение – Use case:

А) Промышленная автоматизация АСУ ТП - APCS

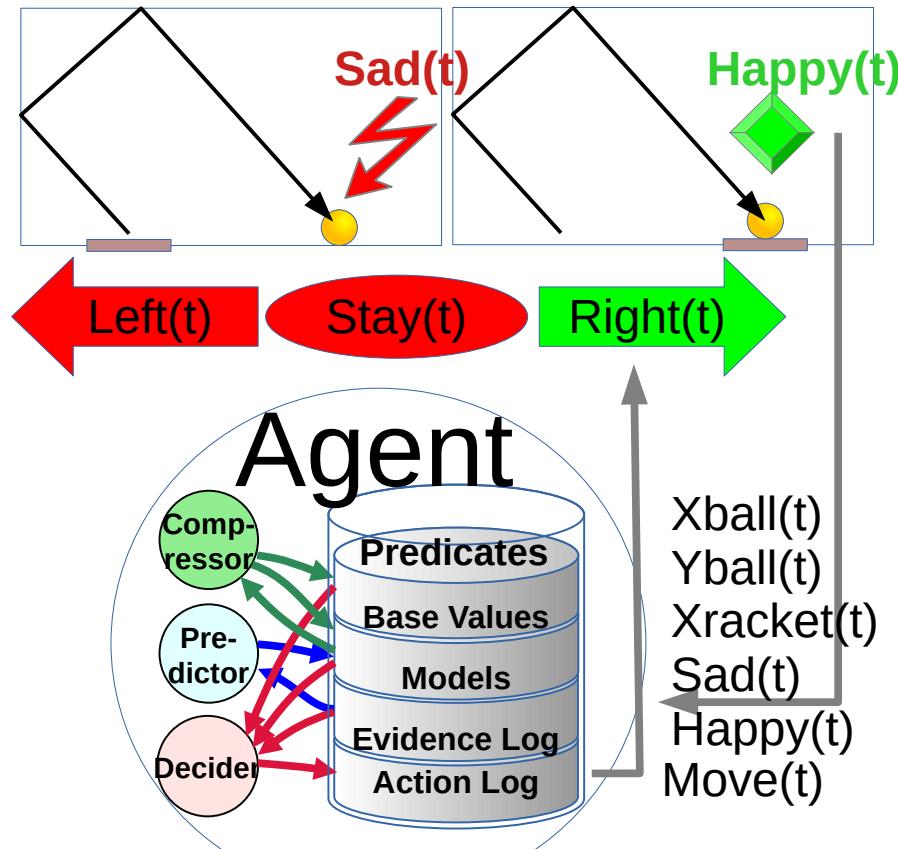


Применение – Use case:

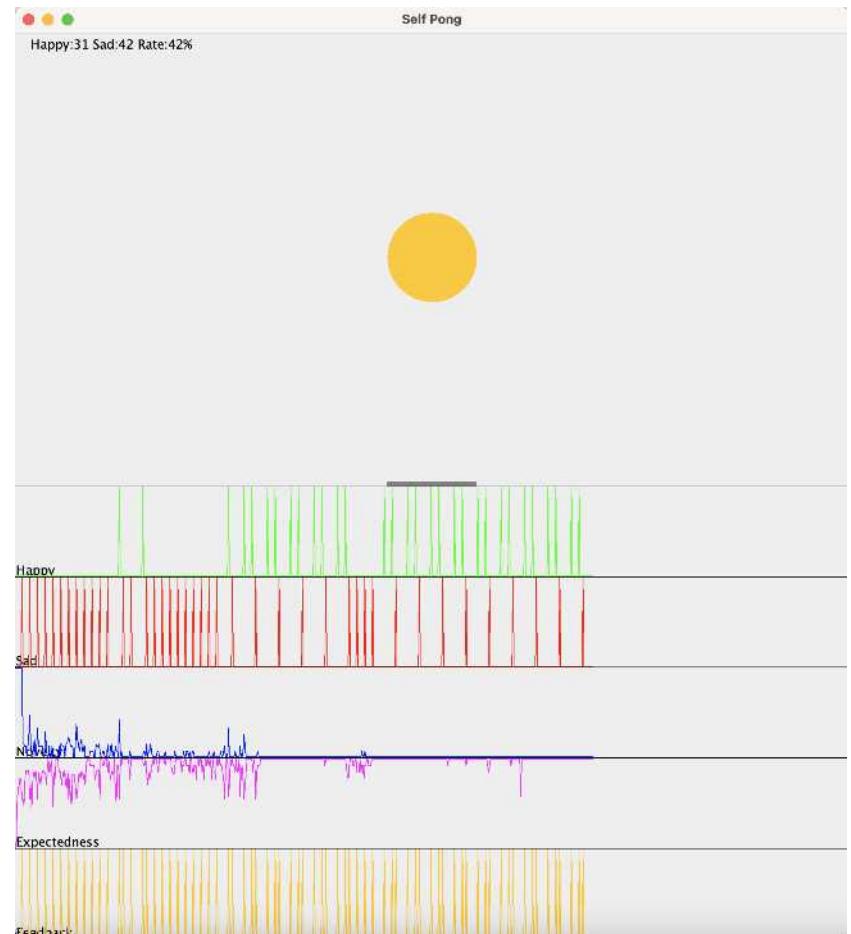
В) Виртуальная игровая среда OpenAI Gym (Atari Breakout)



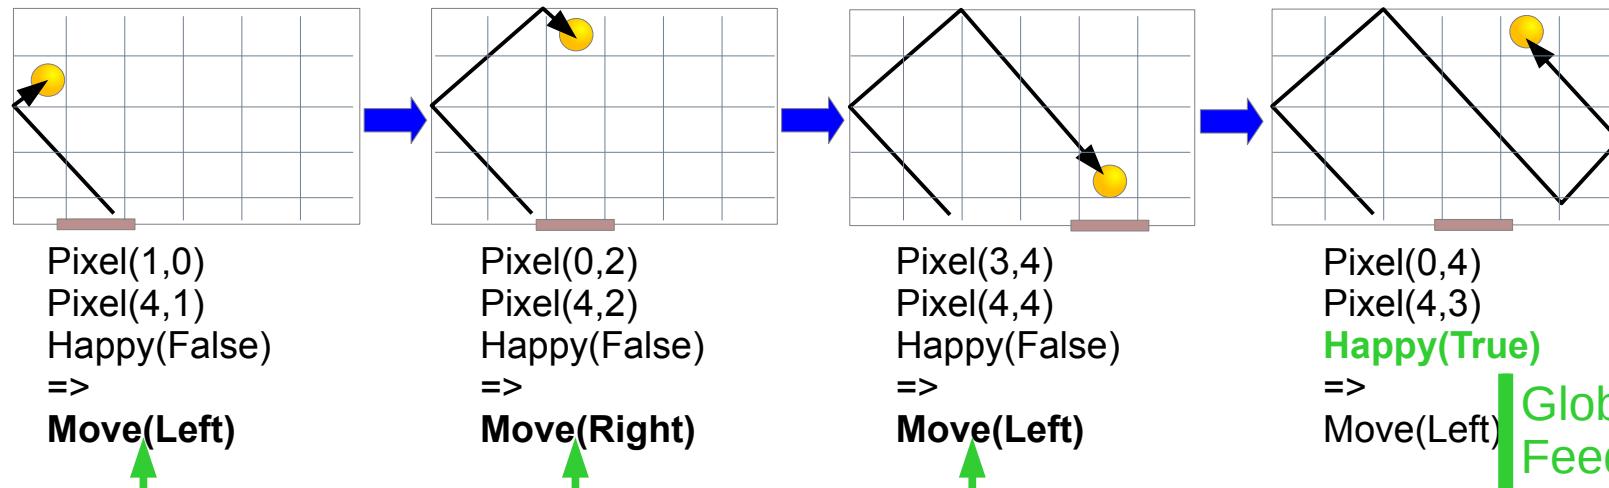
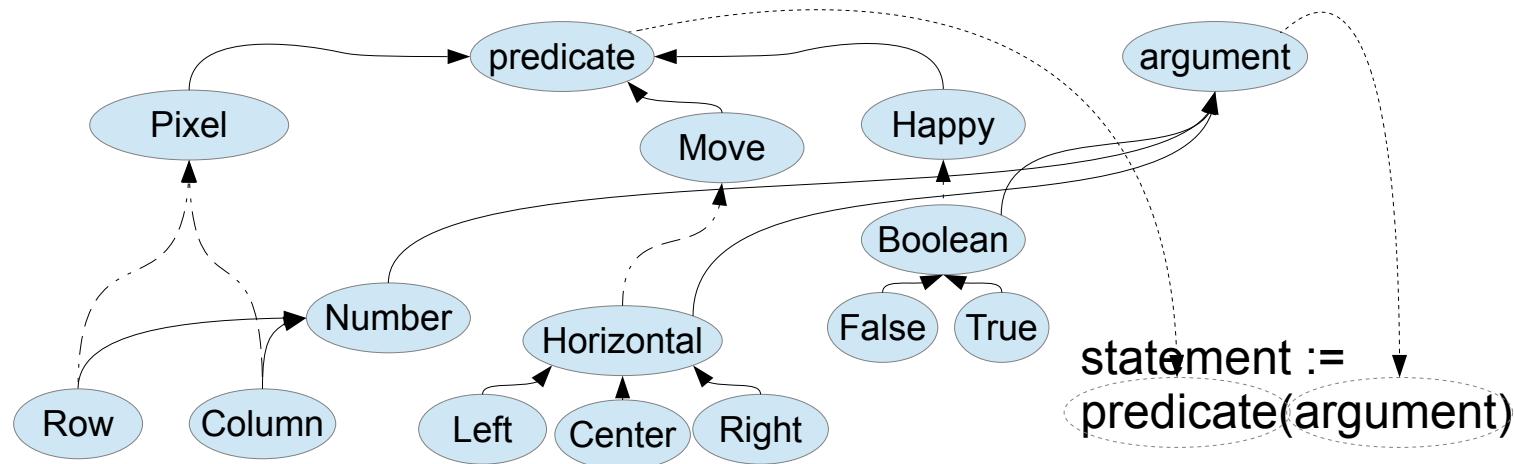
Когнитивная архитектура на графах последовательных состояний State-based History-aware Artificial Reinforcement Intelligence Kernel (Sharik)



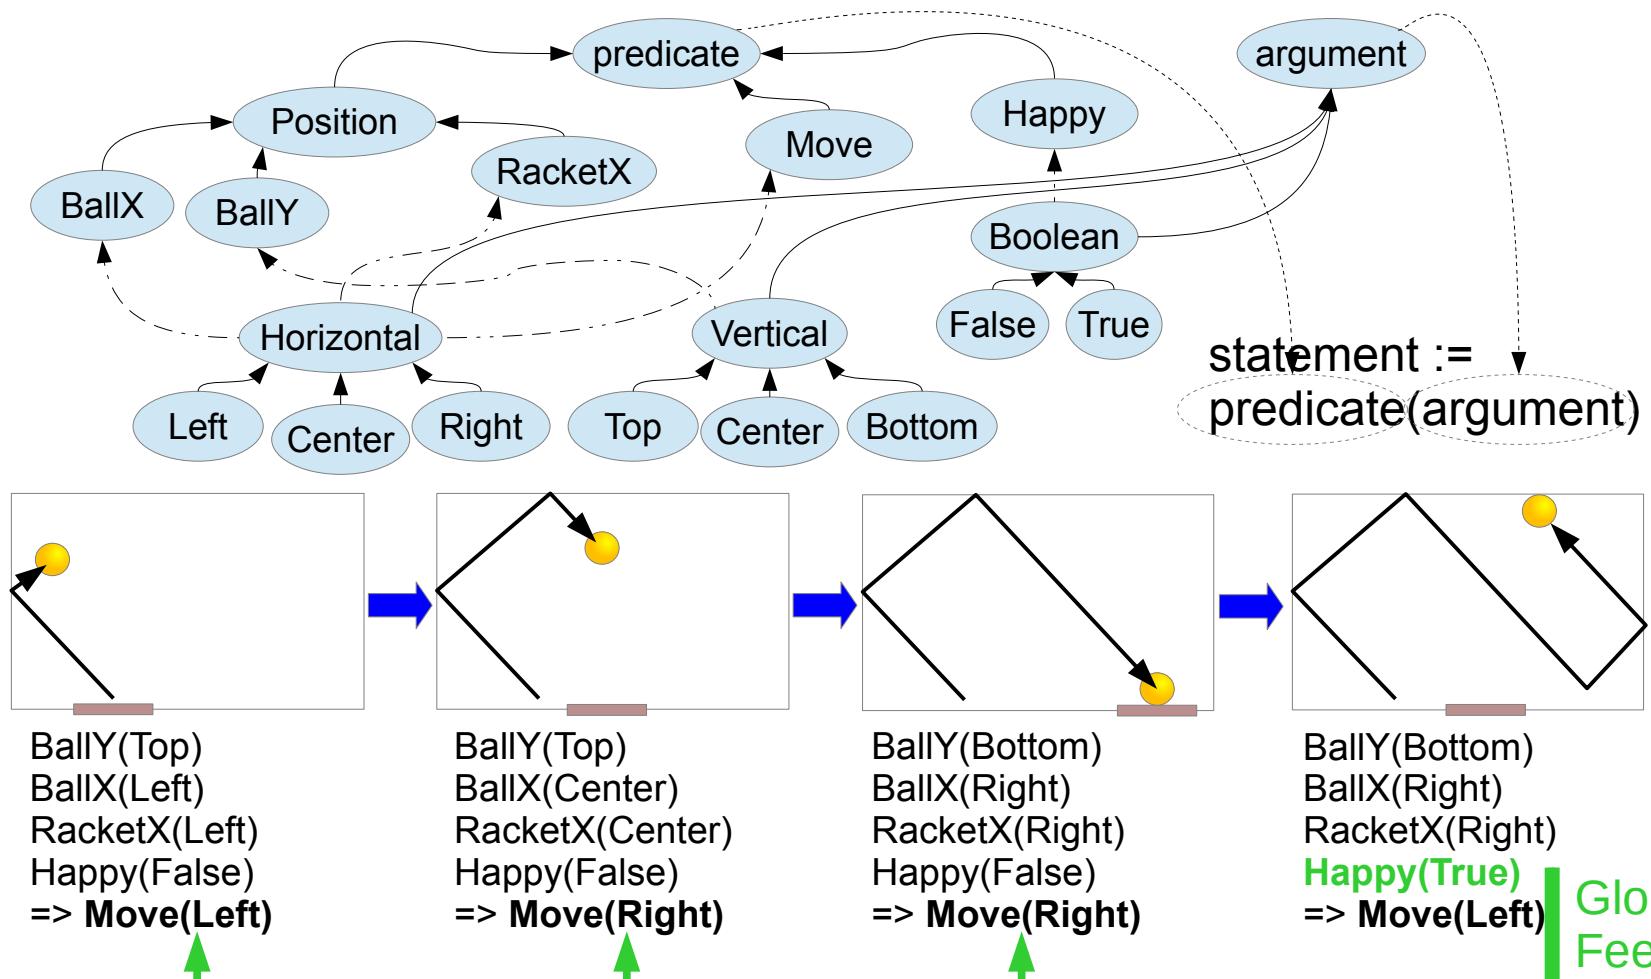
А.Г.Колонин, В.Г.Крюков:
Вычислительная концепция психики,
Статья подана на конференцию
Нейроинформатика-25



Играем в “1 player Ping-Pong” – уровень пикселей

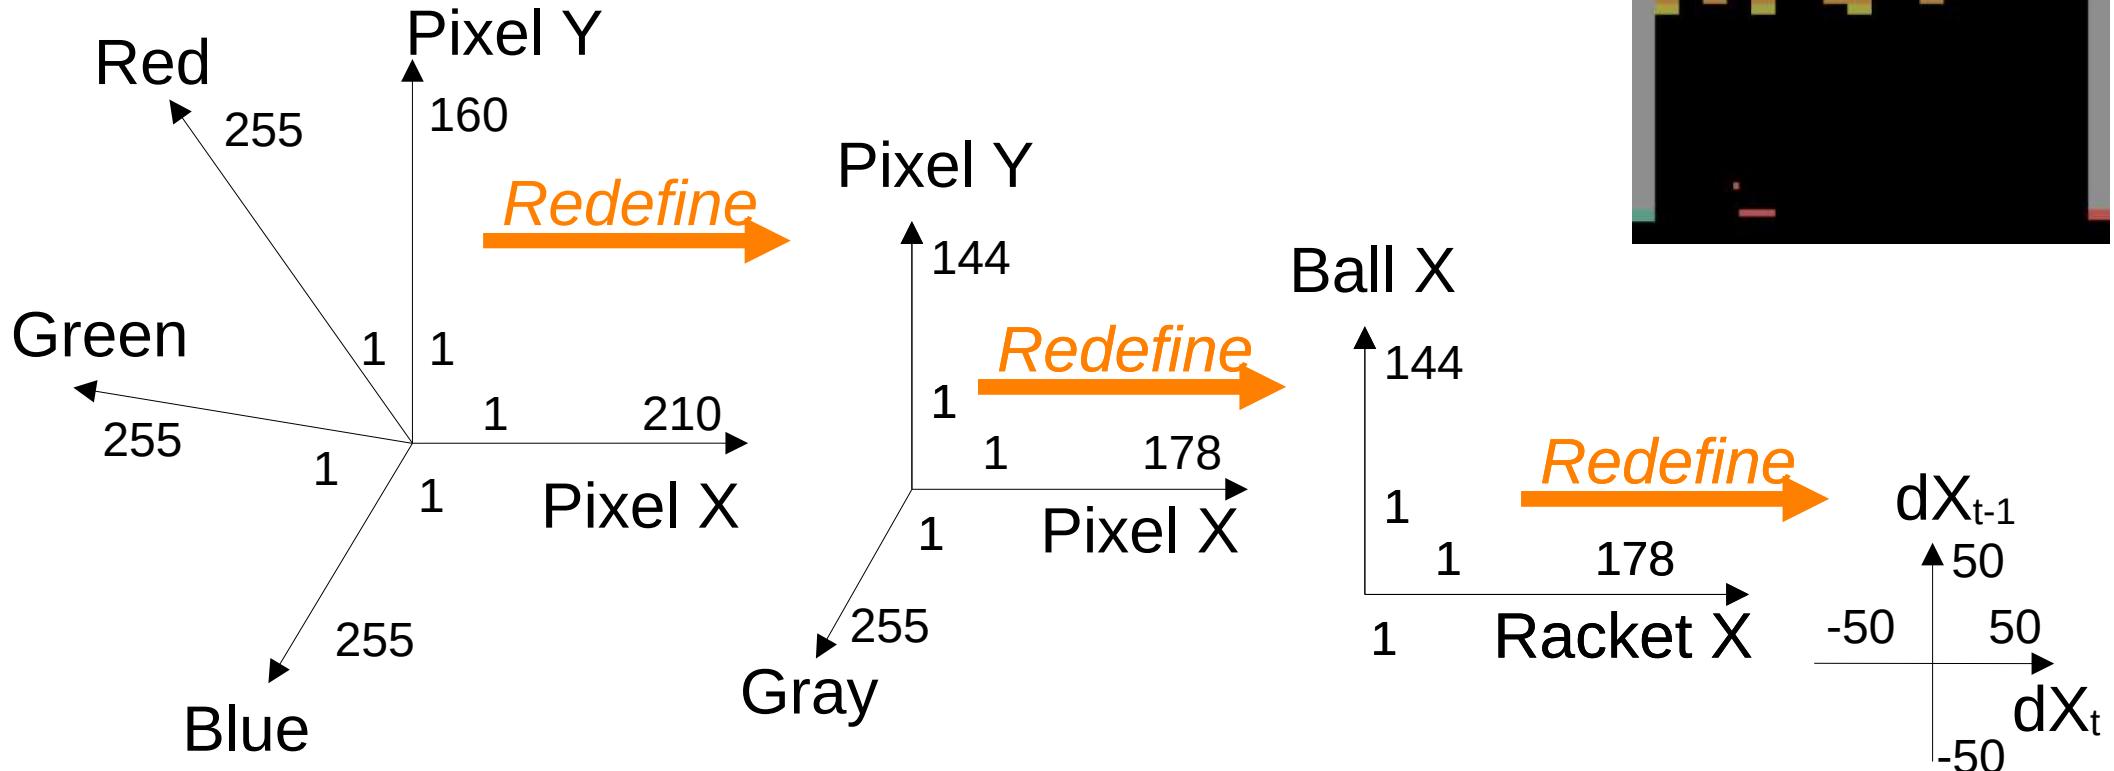


Играем в “1 player Ping-Pong” – уровень объектов

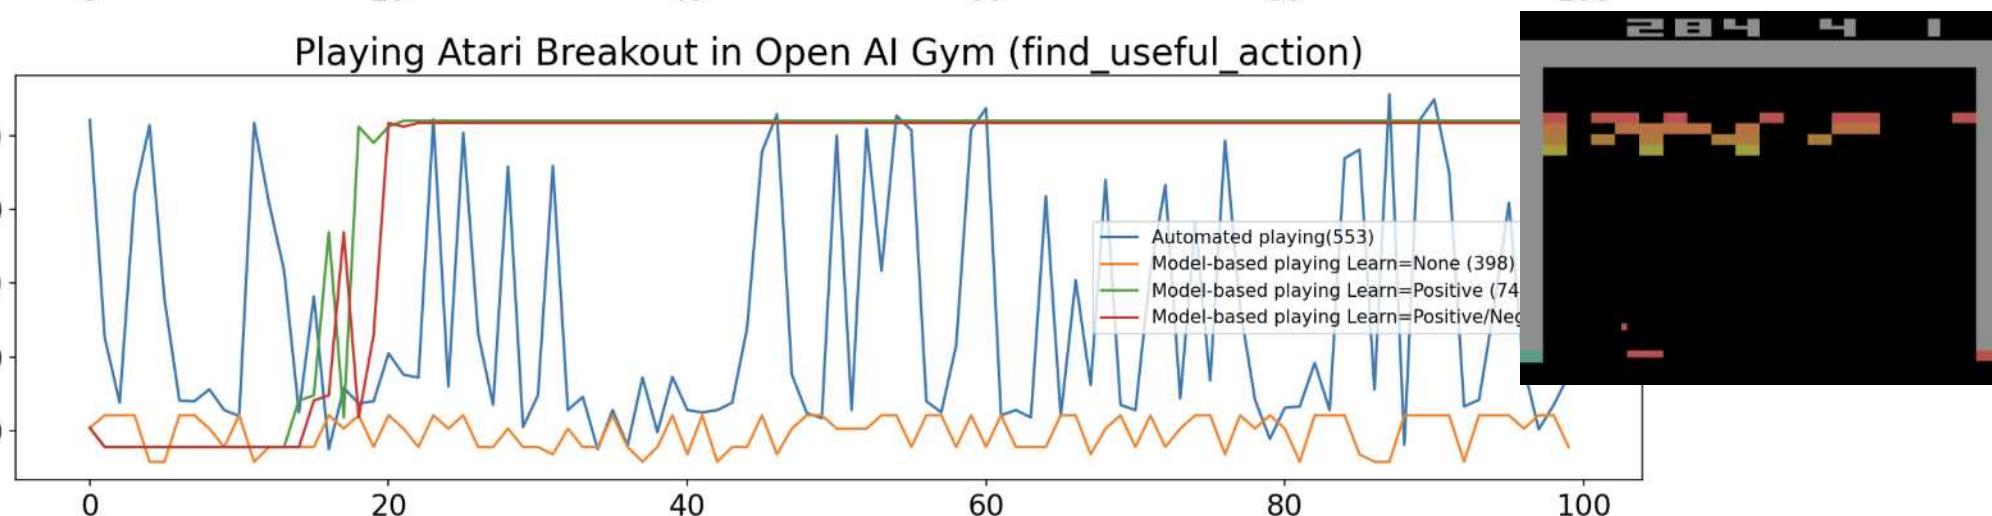
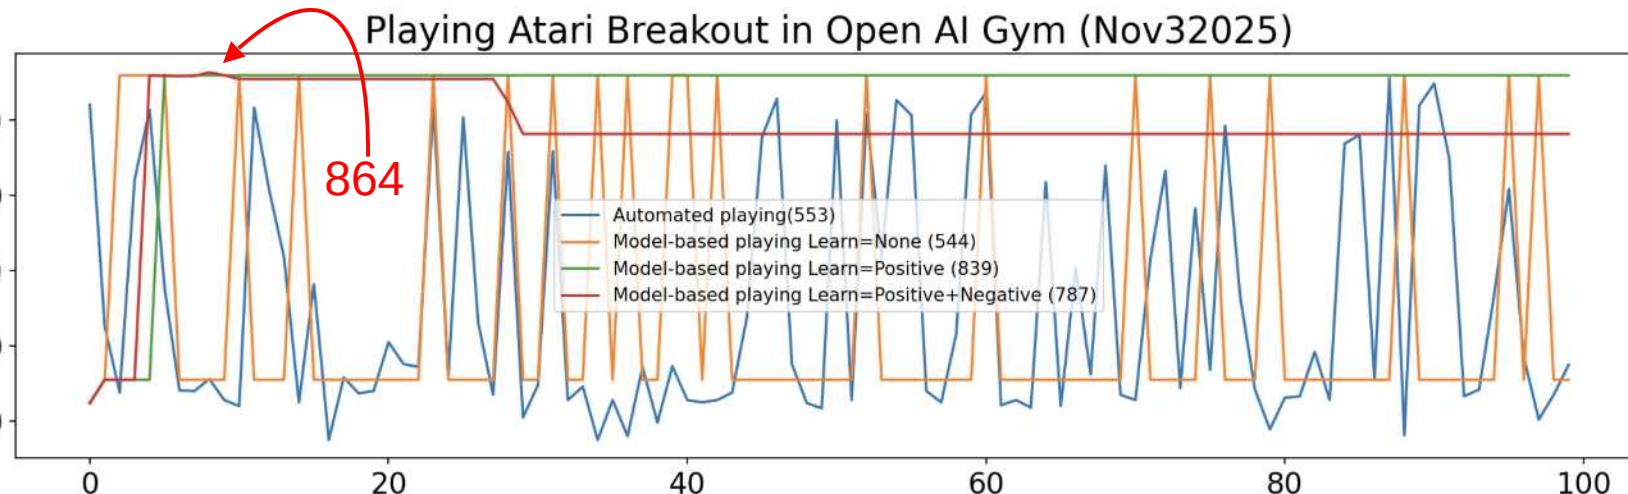


Проблемы (понижения) размерности и (повышения) дискретности

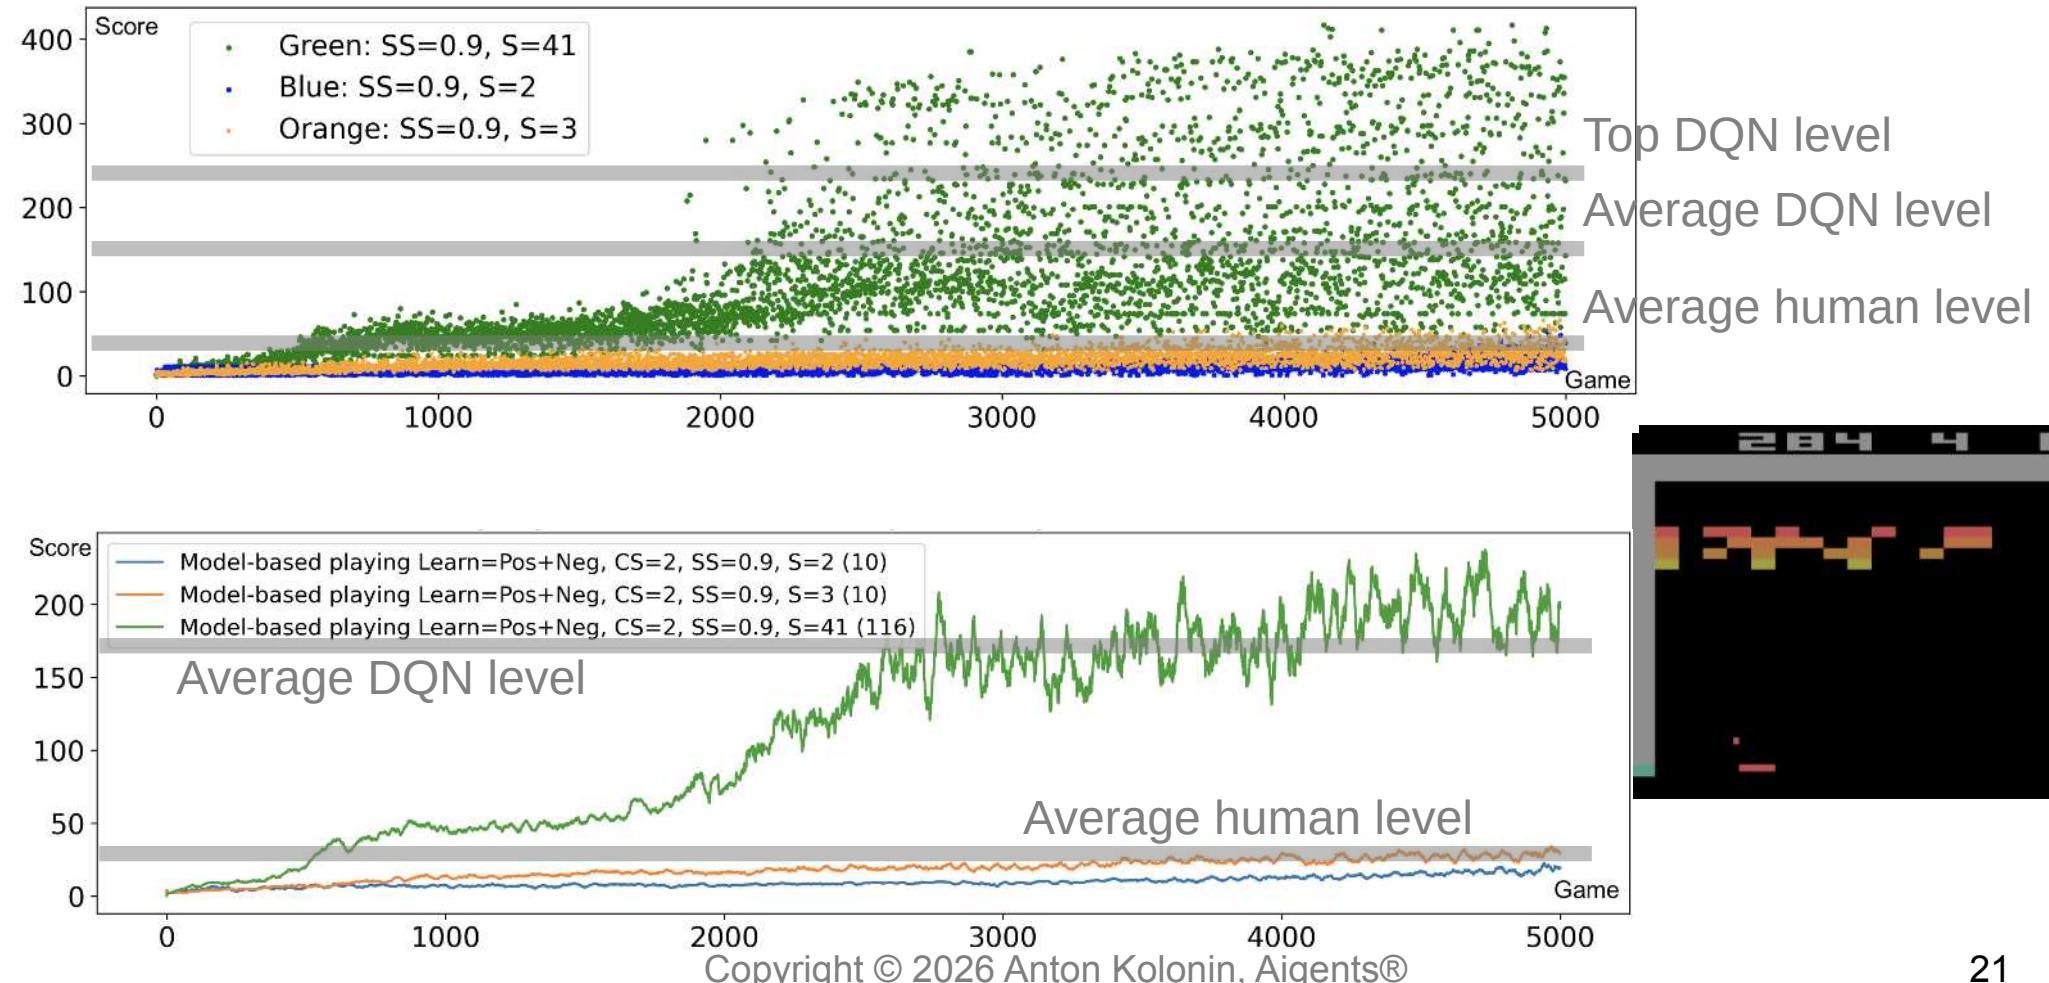
Re-defining environment in Atari Breakout



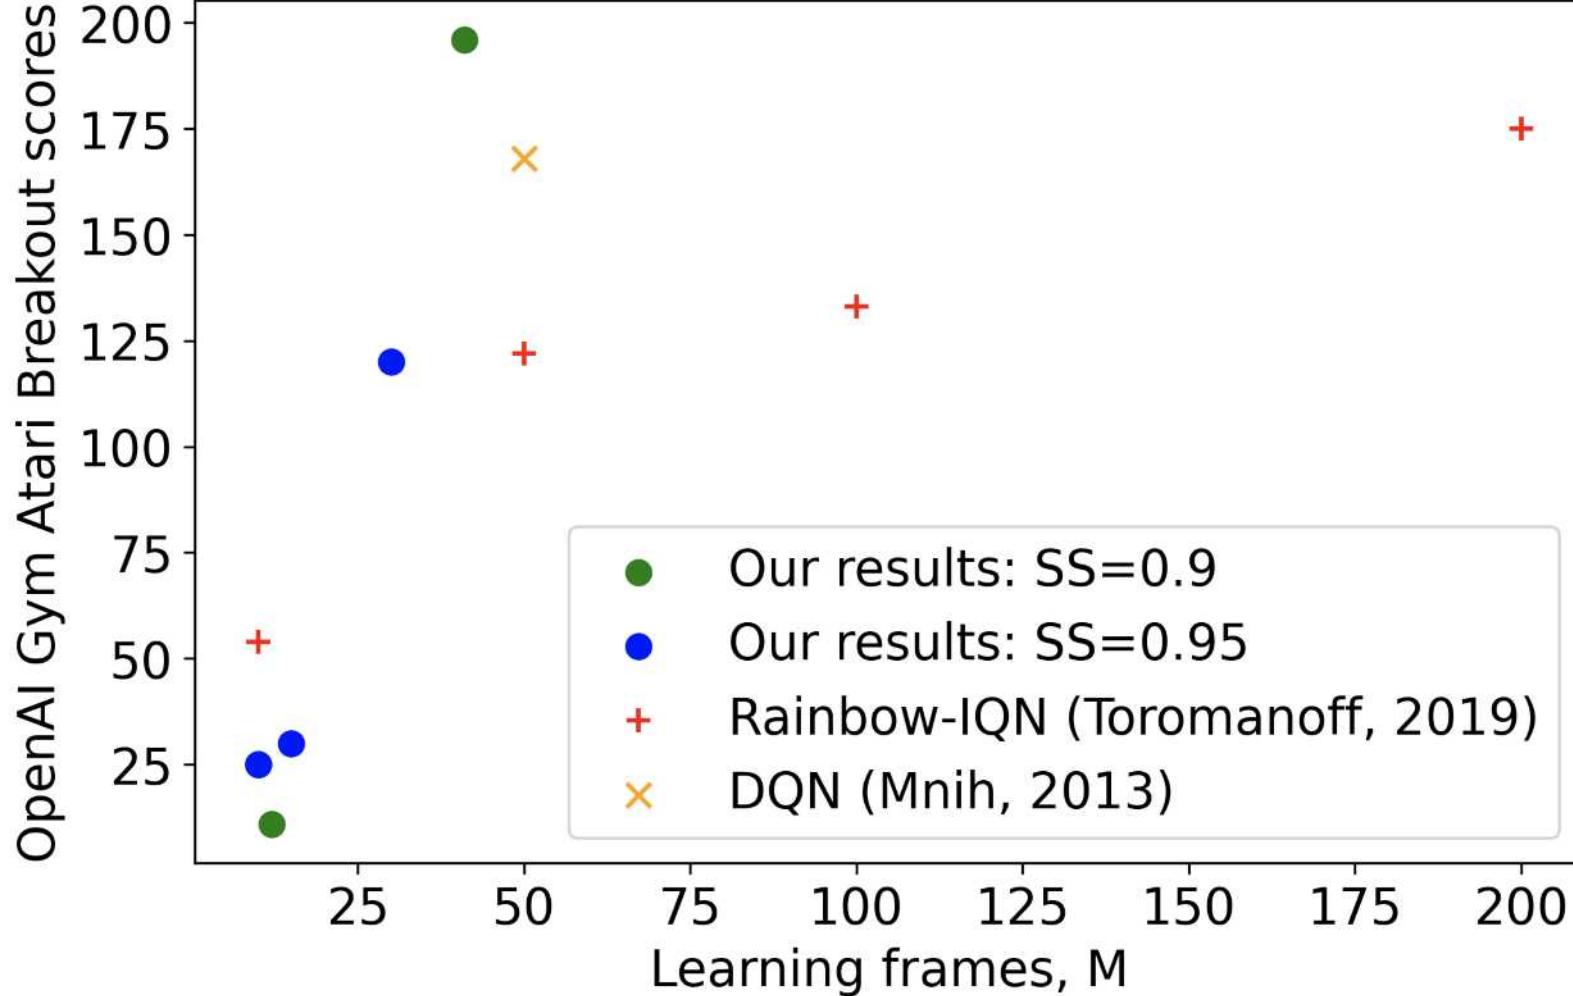
“Imitation learning” – принятие решений на “пред-обученной” модели



Обучение на собственном опыте – переходы между последовательностями



Обучение на собственном опыте – сравнение с “baselines”



Что дальше?

1. Стабилизация обучаемости!
2. Интерпретируемое понижение размерности!
3. Больше окружений – хороших и разных!
4. Кластеризация/сегментация пространства состояний и раздельное исполнение сегментов (*пинг-понг по-македонски*)?
5. Прикладное применение – промышленная автоматизация?
6. Поддержка иерархий/гетерархий пространств состояний?*
7. Формализация перевода графов состояний в языки программной логики (“суперкомпиляция”)?**

Промышленная автоматизация – постановка эксперимента

Рекомендации и предупреждения

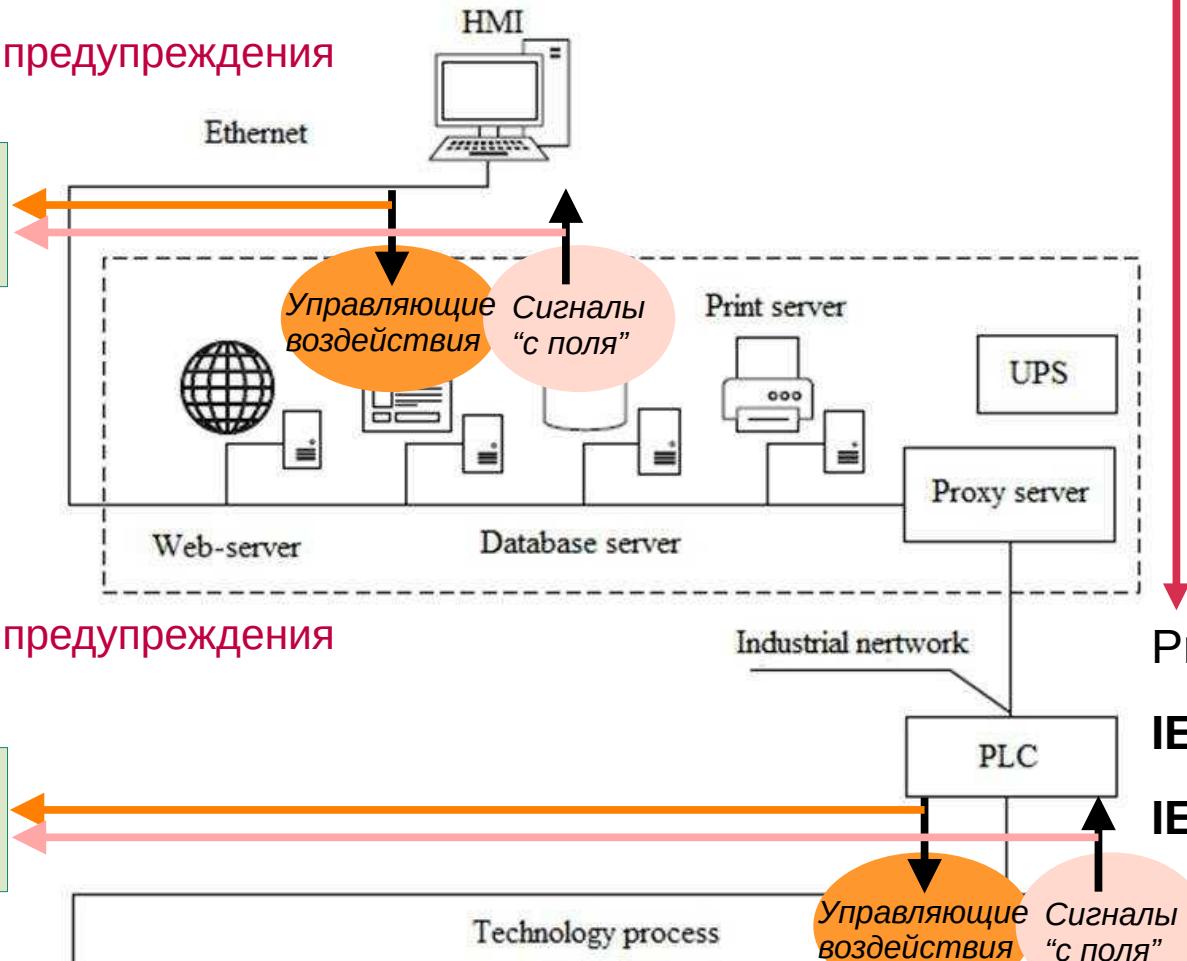
Interpretable AI
("верхний уровень")

Рекомендации и предупреждения

Interpretable AI
("нижний уровень")

???

???



"Суперкомпиляция"

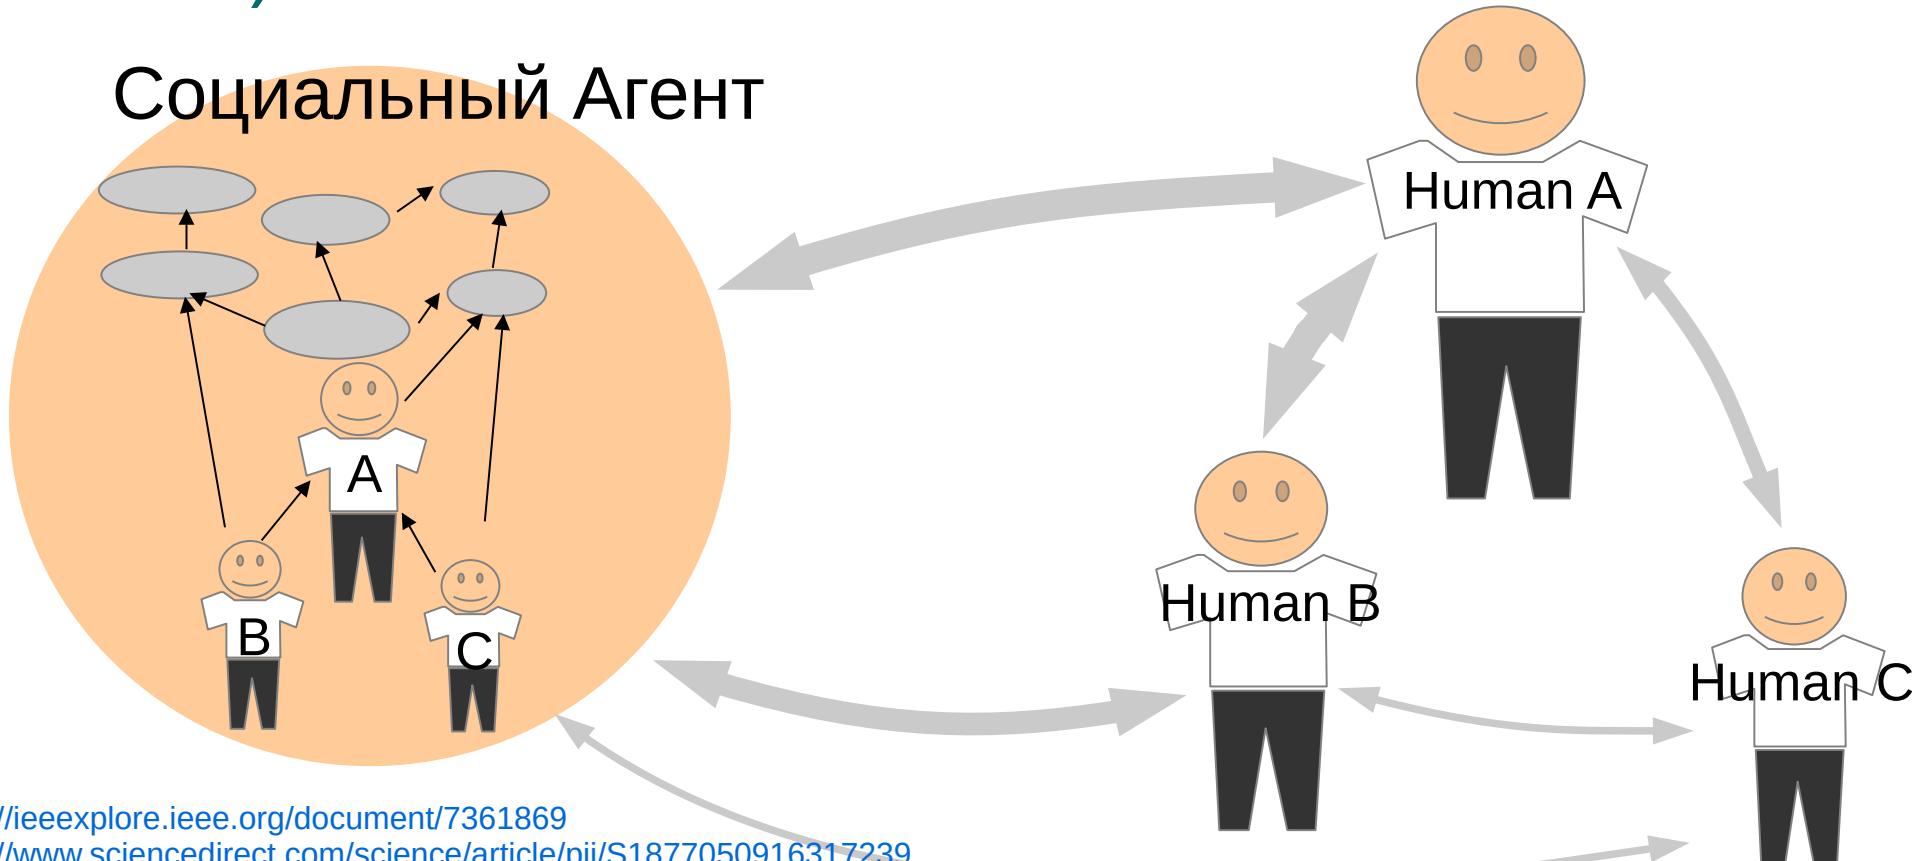
- настройка,
оптимизация
и доработка
программной логики на
основе выученных
(моделей) графов
переходов

Programmable logic

IEC 61131 (synchronous)

IEC 61499 (asynchronous)

Система поддержки принятия решений (СППР) на основе коллективного интеллекта

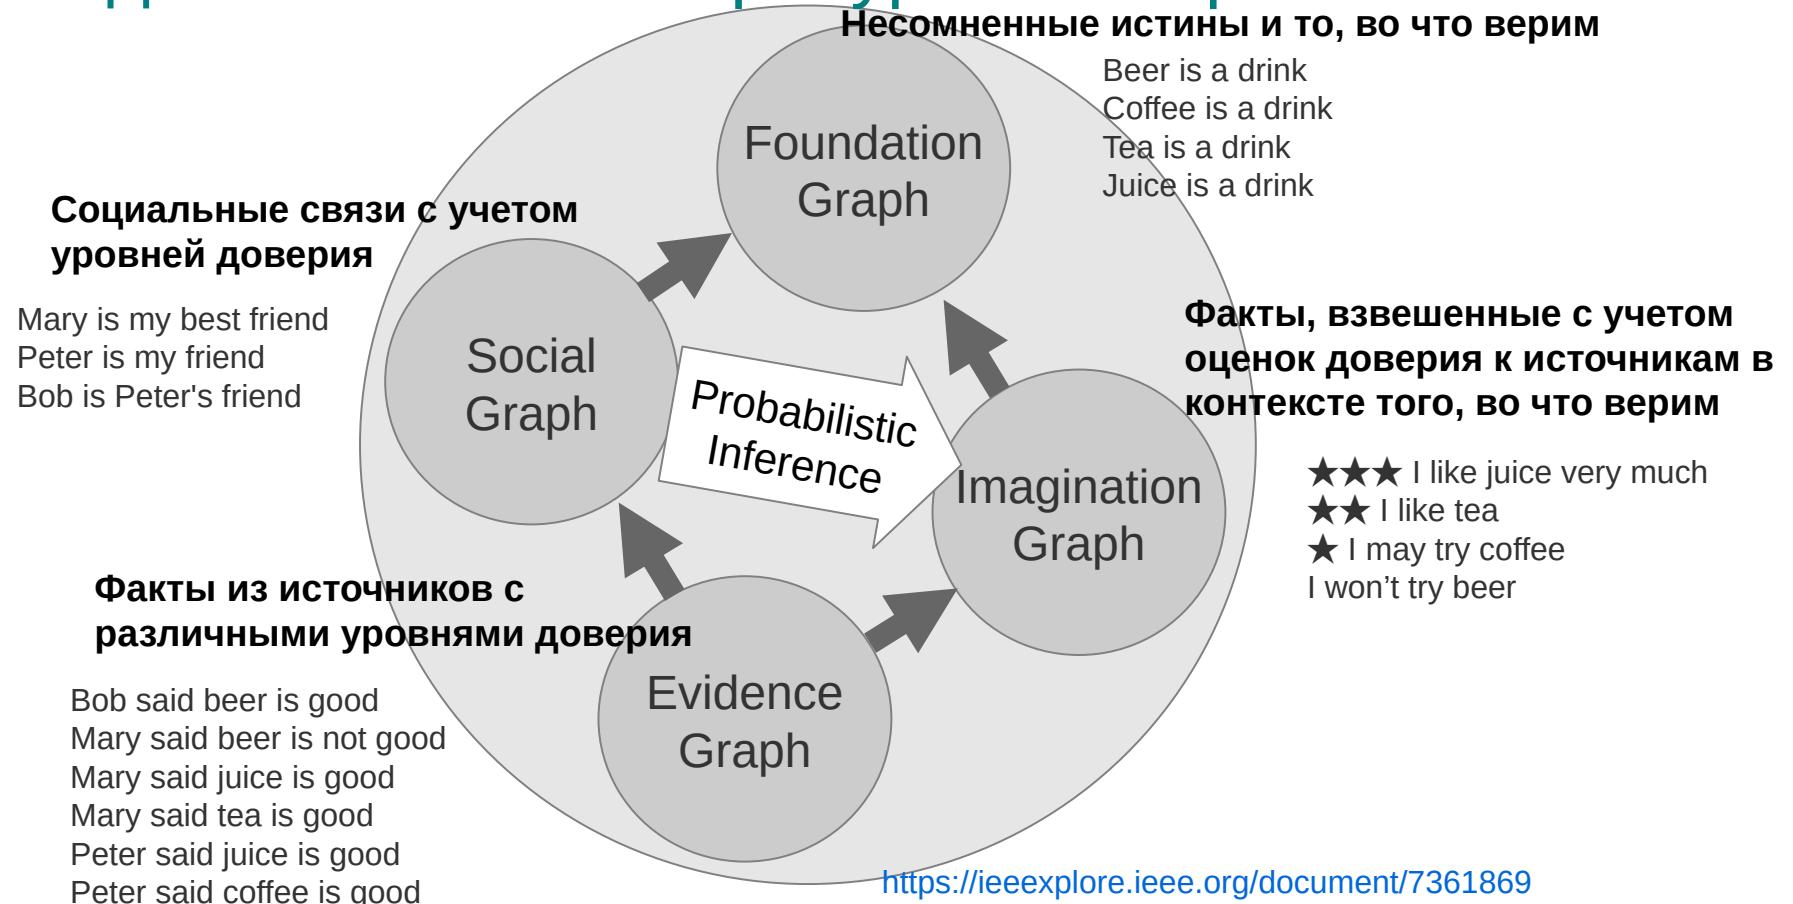


<https://ieeexplore.ieee.org/document/7361869>

<https://www.sciencedirect.com/science/article/pii/S1877050916317239>

https://link.springer.com/chapter/10.1007/978-3-319-97676-1_10

Когнитивно-поведенческая модель на основе социального доказательства и ресурсного ограничения

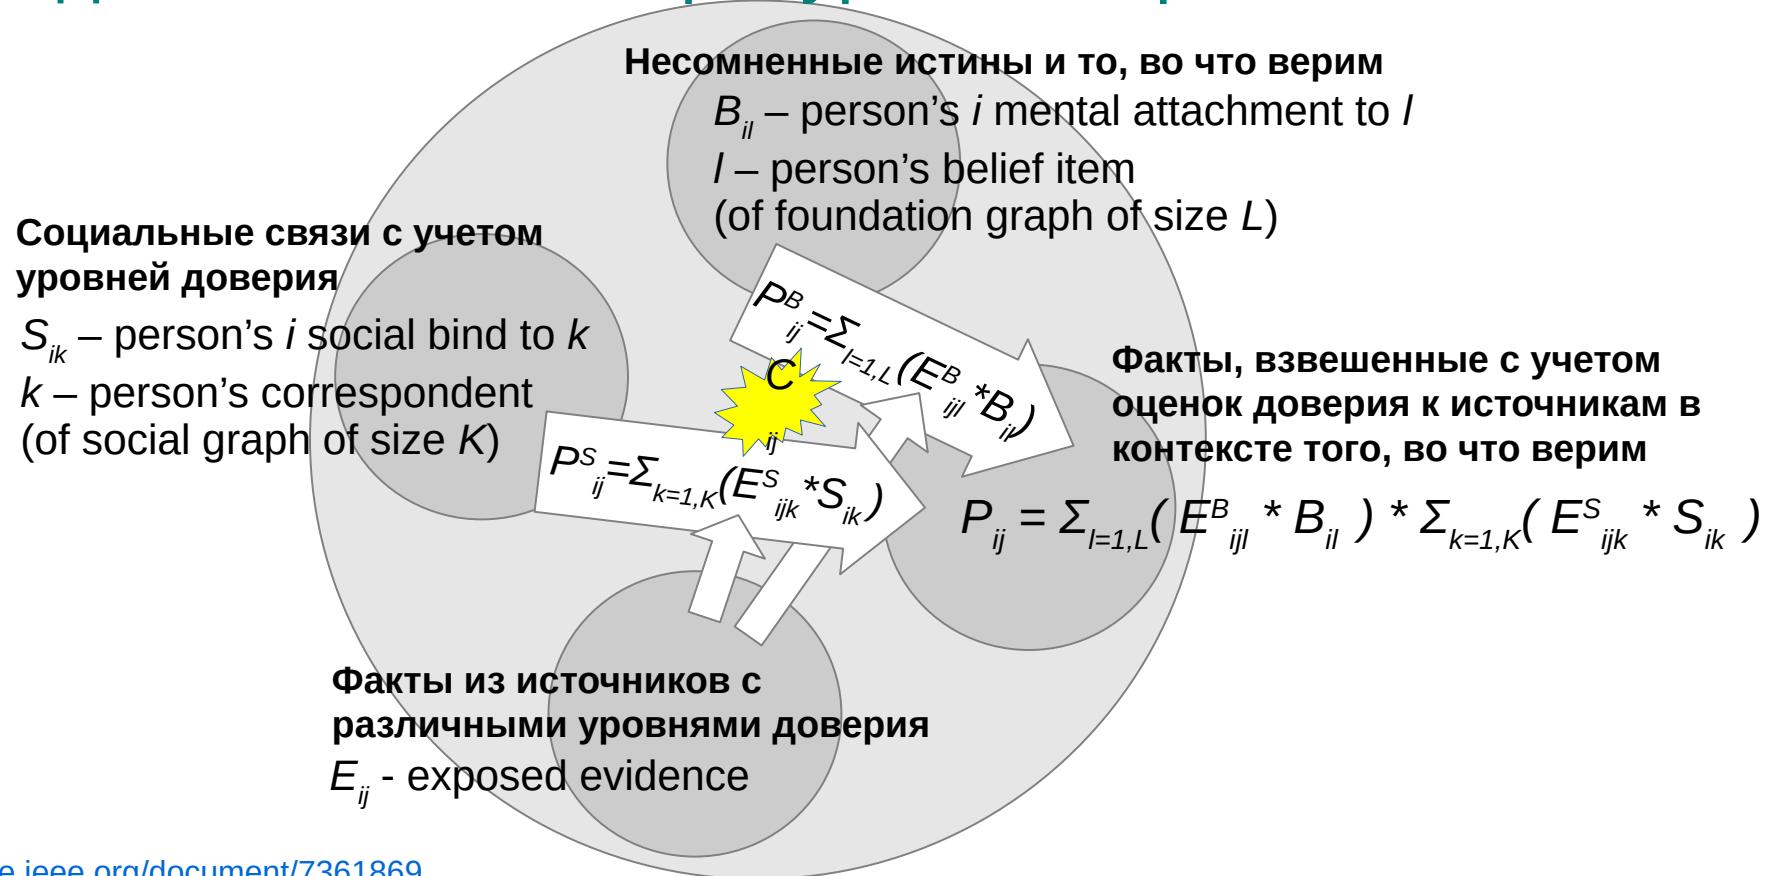


<https://ieeexplore.ieee.org/document/7361869>

<https://www.sciencedirect.com/science/article/pii/S1877050916317239>

https://link.springer.com/chapter/10.1007/978-3-319-97676-1_10

Когнитивно-поведенческая модель на основе социального доказательства и ресурсного ограничения



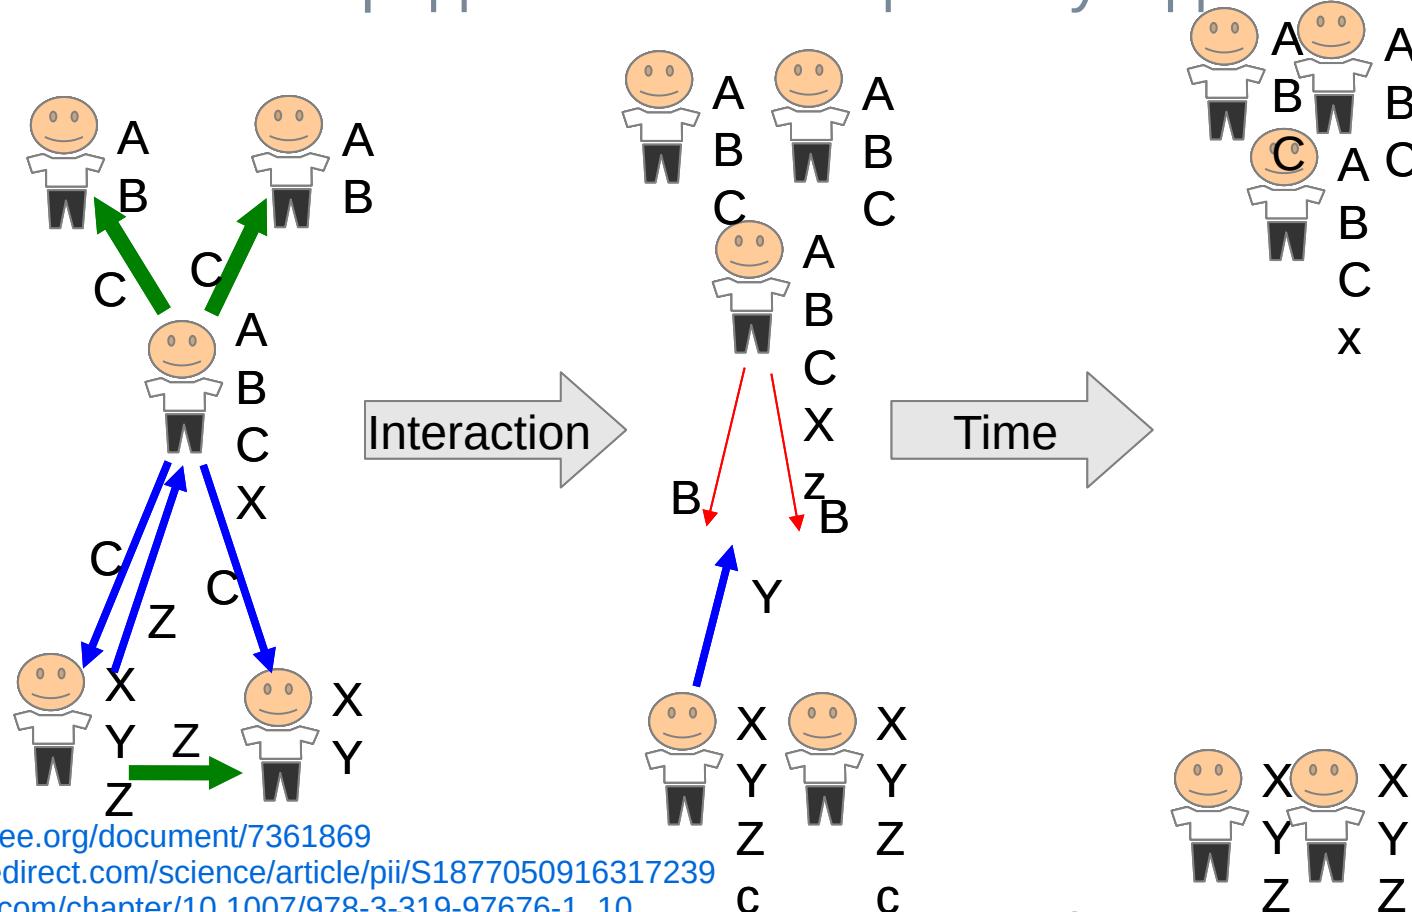
<https://ieeexplore.ieee.org/document/7361869>

<https://www.sciencedirect.com/science/article/pii/S1877050916317239>

https://link.springer.com/chapter/10.1007/978-3-319-97676-1_10

Когнитивно-поведенческая модель на основе социального доказательства и ресурсного ограничения

Помогает предсказывать социальную динамику

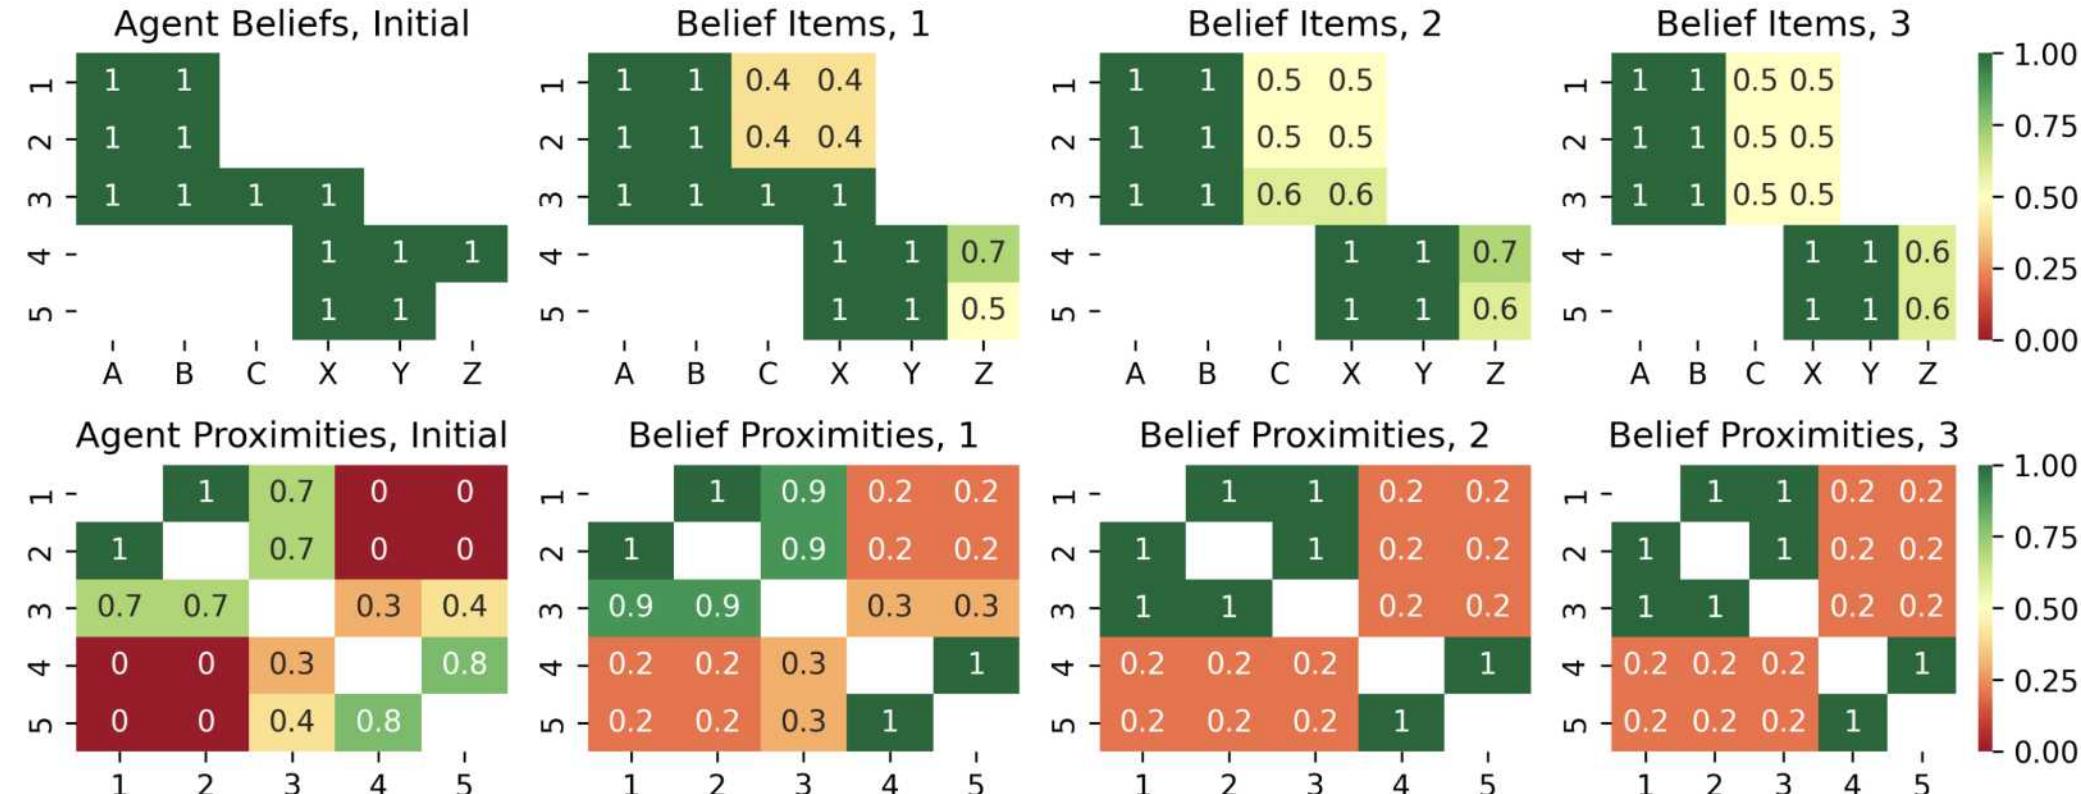


<https://ieeexplore.ieee.org/document/7361869>

<https://www.sciencedirect.com/science/article/pii/S1877050916317239>

https://link.springer.com/chapter/10.1007/978-3-319-97676-1_10

Симуляция: социальная ограниченность, когнитивный ресурс



Results of three rounds of multi-agent simulation with the forgetting threshold peer threshold = 0.5, the social relationship threshold forgetting threshold = 0.0 (limiting social connections K without constraint on belief capacity L). Top row: values of belief items A, B, C, X, Y, Z for five agents 1, 2, 3, 4, 5. Bottom row: social proximity matrices between agents, estimated as the cosine similarity of their beliefs. From left to right: the initial state before the simulation, and then the updated states of beliefs and proximities after three subsequent rounds of multi-agent communication.

Спасибо за внимание! Вопросы?

Антон Колонин

akolonin@aigents.com

Telegram: akolonin

Запись семинара по
теме доклада



Статья по теме доклада,
принятая на конференцию
Нейроинформатика-2025

